人工智能训练师（三级）

技能操作复习题

（含参考答案）

Made by QuadAIT

目 录

1.1 1

1.1.1 1

1.1.2 3

1.1.3 5

1.1.4 7

1.1.5 9

1.2 11

1.2.1 11

1.2.2 12

1.2.3 13

1.2.4 14

1.2.5 16

2.1 17

2.1.1 17

2.1.2 20

2.1.3 23

2.1.4 27

2.1.5 34

2.2 40

2.2.1 40

2.2.2 43

2.2.3 46

2.2.4 51

2.2.5 55

3.1 59

3.1.1 59

3.1.2 60

Made by QuadAIT

3.1.3 61
3.1.4 62
3.1.5 63
3.2 64
3.2.1 64
3.2.2 66
3.2.3 68
3.2.4 70
3.2.5 72
4.1 75
4.1.1 75
4.1.2 77
4.1.3 79
4.1.4 80
4.1.5 81
4.2 82
4.2.1 82
4.2.2 83
4.2.3 84
4.2.4 85
4.2.5 96

Made by QuadAIT

1.1.1

In [1]:
```
import pandas as pd
import numpy as np

# 读取数据集 1分
data = pd.read_csv('patient_data.csv')
```

In [2]:
```
# 1. 统计住院天数超过7天的患者数量及其占比
# 创建新列'RiskLevel'，根据住院天数判断风险等级 3分
data['RiskLevel'] = np.where(data['DaysInHospital'] > 7, '高风险患者', '低风险患者')
# 统计不同风险等级的患者数量 2分
risk_counts = data['RiskLevel'].value_counts()
# 计算高风险患者占比 1分
high_risk_ratio = risk_counts['高风险患者'] / len(data)
# 计算低风险患者占比 1分
low_risk_ratio = risk_counts['低风险患者'] / len(data)

# 输出结果
print("高风险患者数量:", risk_counts['高风险患者'])
print("低风险患者数量:", risk_counts['低风险患者'])
print("高风险患者占比:", high_risk_ratio)
print("低风险患者占比:", low_risk_ratio)
```

```
高风险患者数量: 413
低风险患者数量: 587
高风险患者占比: 0.413
低风险患者占比: 0.587
```

1.1.1-1.jpg

In [3]:
```
# 2. 统计不同BMI区间中高风险患者的比例和统计不同BMI区间中的患者数
# 定义BMI区间和标签
bmi_bins = [0, 18.5, 24, 28, np.inf]
bmi_labels = ['偏瘦', '正常', '超重', '肥胖']
# 根据BMI值划分指定区间 4分
data['BMIRange'] = pd.cut(data['BMI'], bins=bmi_bins, labels=bmi_labels, right=Fals
e)  # 使用左闭右开区间
# 计算每个BMI区间中高风险患者的比例 2分
bmi_risk_rate = data.groupby('BMIRange')['RiskLevel'].apply(lambda x: (x == '高风险
患者').mean())
# 统计每个BMI区间的患者数量 1分
bmi_patient_count = data['BMIRange'].value_counts()

# 输出结果
print("BMI区间中高风险患者的比例和患者数:")
print(bmi_risk_rate)
print(bmi_patient_count)
```

```
BMI区间中高风险患者的比例和患者数:
BMIRange
偏瘦    0.444444
正常    0.406699
超重    0.388235
肥胖    0.415094
Name: RiskLevel, dtype: float64
BMIRange
肥胖    477
正常    209
超重    170
偏瘦    144
Name: count, dtype: int64
```

1.1.1-2.jpg

Made by QuadAIT

In [4]:
```
# 3. 统计不同年龄区间中高风险患者的比例和统计不同年龄区间中的患者数
# 定义年龄区间和标签
age_bins = [0, 26, 36, 46, 56, 66, np.inf]
age_labels = ['≤25岁', '26-35岁', '36-45岁', '46-55岁', '56-65岁', '>65岁']
# 根据年龄值划分指定区间 4分
data['AgeRange'] = pd.cut(data['Age'], bins=age_bins, labels=age_labels, right=False)  # 使用左闭右开区间
# 计算每个年龄区间中高风险患者的比例 2分
age_risk_rate = data.groupby('AgeRange')['RiskLevel'].apply(lambda x: (x == '高风险患者').mean())
# 统计每个年龄区间的患者数量 1分
age_patient_count = data['AgeRange'].value_counts()

# 输出结果
print("年龄区间中高风险患者的比例和患者数:")
print(age_risk_rate)
print(age_patient_count)
```

```
年龄区间中高风险患者的比例和患者数:
AgeRange
≤25岁      0.456693
26-35岁    0.398496
36-45岁    0.386364
46-55岁    0.444444
56-65岁    0.401575
>65岁       0.401254
Name: RiskLevel, dtype: float64
AgeRange
>65岁       319
46-55岁     162
26-35岁     133
36-45岁     132
≤25岁       127
56-65岁     127
Name: count, dtype: int64
```

1.1.1-3.jpg

Made by QuadAIT

1.1.2

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
# 读取数据集 2分
data = pd.read_csv('sensor_data.csv')
```

In [2]:
```
# 1. 传感器数据统计
# 对传感器类型进行分组，并计算每个组的数据数量和平均值 3分
sensor_stats = data.groupby('SensorType')['Value'].agg(['count', 'mean'])
# 输出结果
print("传感器数据数量和平均值:")
print(sensor_stats)
```

```
传感器数据数量和平均值:
                count       mean
SensorType
Humidity         2065  48.978302
Light            1950  49.439011
SoilMoisture     1951  49.325119
SoilPH           2029  49.865460
Temperature      2005  49.847153
```

1.1.2-1.jpg

In [3]:
```
# 2. 按位置统计温度和湿度数据
# 筛选出温度和湿度数据，然后按位置和传感器类型分组，计算每个组的平均值 2分
location_stats = data[data['SensorType'].isin(['Temperature', 'Humidity'])].groupby
(['Location', 'SensorType'])['Value'].mean().unstack()
# 输出结果
print("每个位置的温度和湿度数据平均值:")
print(location_stats)
```

```
每个位置的温度和湿度数据平均值:
SensorType   Humidity  Temperature
Location
Field1      49.036008    50.482617
Field2      47.379411    49.874282
Field3      49.583266    48.761804
Field4      49.955498    50.241608
```

1.1.2-2.jpg

Made by QiaoAIT

In [4]:
```
# 3. 数据清洗和异常值处理
# 标记异常值 3分
data['is_abnormal'] = np.where(
    ((data['SensorType'] == 'Temperature') & ((data['Value'] < -10) | (data['Value'] > 50))) |
    ((data['SensorType'] == 'Humidity') & ((data['Value'] < 0) | (data['Value'] > 100))),
    True, False
)
# 输出异常值数量 2分
print("异常值数量:", data['is_abnormal'].sum())
# 填补缺失值
# 使用前向填充和后向填充的方法填补缺失值 4分
data['Value'].fillna(method='ffill', inplace=True)
data['Value'].fillna(method='bfill', inplace=True)
# 保存清洗后的数据
# 删除用于标记异常值的列，并将清洗后的数据保存到新的CSV文件中 4分
cleaned_data = data.drop(columns=['is_abnormal'])
cleaned_data.to_csv('cleaned_sensor_data.csv', index=False)
print("数据清洗完成，已保存为 'cleaned_sensor_data.csv'")
```

```
异常值数量: 1011
数据清洗完成，已保存为 'cleaned_sensor_data.csv'
```

Made by QuadATT

1.1.3

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
# 读取数据集
data = pd.read_csv('credit_data.csv')
```

In [2]:
```
# 1. 数据完整性审核
missing_values = data.isnull().sum()        #数据缺失值统计 2分
duplicate_values = data.duplicated().sum()      #数据重复值统计 2分
# 输出结果
print("缺失值统计:")
print(missing_values)
print("重复值统计:")
print(duplicate_values)
```

```
缺失值统计:
CustomerID            0
Name                  0
Age                   1
Income                1
LoanAmount            0
LoanTerm              0
CreditScore           0
Default               0
TransactionHistory    0
dtype: int64
重复值统计:
0
```

1.1.3-1.jpg

Made by QuadAIT

In [3]:
```
# 2. 数据合理性审核
data['is_age_valid'] = data['Age'].between(18, 70)                #Age数据的合理性审核 2分
data['is_income_valid'] = data['Income'] > 2000                   #Income数据的合理性审核 2分
data['is_loan_amount_valid'] = data['LoanAmount'] < (data['Income'] * 5)       #LoanAmount数据的合理性审核 2分
data['is_credit_score_valid'] = data['CreditScore'].between(300, 850)    #CreditScore数据的合理性审核 2分
# 合理性检查结果
validity_checks = data[['is_age_valid', 'is_income_valid', 'is_loan_amount_valid', 'is_credit_score_valid']].all(axis=1)
data['is_valid'] = validity_checks
# 输出结果
print("数据合理性检查:")
print(data[['is_age_valid', 'is_income_valid', 'is_loan_amount_valid', 'is_credit_score_valid', 'is_valid']].describe())
```

```
数据合理性检查:
       is_age_valid is_income_valid is_loan_amount_valid  \
count          1000            1000                 1000
unique            2               2                    2
top            True            True                 True
freq            999             999                  796

       is_credit_score_valid is_valid
count                   1000     1000
unique                     1        2
top                     True     True
freq                    1000      795
```

1.1.3-2.jpg

In [4]:
```
# 3. 数据清洗和异常值处理
# 标记不合理数据
invalid_rows = data[~data['is_valid']]
# 删除不合理数据行
cleaned_data = data[data['is_valid']]
# 删除标记列
cleaned_data = cleaned_data.drop(columns=['is_age_valid', 'is_income_valid', 'is_loan_amount_valid', 'is_credit_score_valid', 'is_valid'])
# 保存清洗后的数据
cleaned_data.to_csv('cleaned_credit_data.csv', index=False)
print("数据清洗完成，已保存为 'cleaned_credit_data.csv'")
```

```
数据清洗完成，已保存为 'cleaned_credit_data.csv'
```

Made by QuadAIT

1.1.4

In [1]:
```
import pandas
import numpy as np
import matplotlib.pyplot as plt

# 1. 数据采集
# 从本地文件中读取数据  2分
data =  pandas.read_csv('user_behavior_data.csv')
print("数据采集完成，已加载到DataFrame中")

# 打印数据的前5条记录  2分
print(data.head())
```

```
数据采集完成，已加载到DataFrame中
   UserID UserName  Age  Gender    Location   LastLogin  PurchaseAmount  \
0       1   User_1   62  Female  Location_1  2023-06-10             118
1       2   User_2   65  Female  Location_2  2023-08-14             466
2       3   User_3   18    Male  Location_3  2023-02-17             869
3       4   User_4   21  Female  Location_4  2023-03-14             486
4       5   User_5   21    Male  Location_5  2023-07-26             753

  PurchaseCategory  ReviewScore LoginFrequency
0         Clothing            3        Monthly
1      Electronics            4         Weekly
2    Home & Garden            3         Weekly
3            Books            2         Weekly
4    Home & Garden            1        Monthly
```

In [2]:
```
# 2. 数据清洗与预处理
# 处理缺失值（删除）  2分
data = data.dropna()

# 数据类型转换
data['Age'] = data['Age'].astype(int)    # Age数据类型转换为int 2分
data['PurchaseAmount'] = data['PurchaseAmount'].astype(float) # PurchaseAmount数据类型转换为float  2分
data['ReviewScore'] = data['ReviewScore'].astype(int)    # ReviewScore数据类型转换为int 2分

# 处理异常值  2分
data = data[(data['Age'].between(18, 70)) &
            (data['PurchaseAmount'] > 0) &
            (data['ReviewScore'].between(1, 5))]

# 数据标准化
data['PurchaseAmount'] = (data['PurchaseAmount'] - data['PurchaseAmount'].mean()) / data['PurchaseAmount'].std()  # PurchaseAmount数据标准化 2分
data['ReviewScore'] = (data['ReviewScore'] - data['ReviewScore'].mean()) / data['ReviewScore'].std()        # ReviewScore数据标准化 2分

# 保存清洗后的数据  1分
data.to_csv('cleaned_user_behavior_data.csv', index=False)
print("数据清洗完成，已保存为 'cleaned_user_behavior_data.csv'")
```

```
数据清洗完成，已保存为 'cleaned_user_behavior_data.csv'
```

Made by QuadAIT

In [3]:
```
# 3. 数据统计
# 统计每个购买类别的用户数 2分
purchase_category_counts = data['PurchaseCategory'].value_counts()
print("每个购买类别的用户数:\n", purchase_category_counts)

# 统计不同性别的平均购买金额 2分
gender_purchase_amount_mean = data.groupby('Gender')['PurchaseAmount'].mean()
print("不同性别的平均购买金额:\n", gender_purchase_amount_mean)

# 统计不同年龄段的用户数 2分
bins = [18, 26, 36, 46, 56, 66, np.inf]
labels = ['18-25', '26-35', '36-45', '46-55', '56-65', '65+']
data['AgeGroup'] = pandas.cut(data['Age'], bins=bins, labels=labels, right=False)
age_group_counts = data['AgeGroup'].value_counts().sort_index()
print("不同年龄段的用户数:\n", age_group_counts)
```

```
每个购买类别的用户数:
 PurchaseCategory
Clothing          214
Electronics       213
Home & Garden     203
Food              197
Books             173
Name: count, dtype: int64
```

1.1.4-1.jpg

```
不同性别的平均购买金额:
 Gender
Female   -0.001367
Male      0.001458
Name: PurchaseAmount, dtype: float64
```

1.1.4-2.jpg

```
不同年龄段的用户数:
 AgeGroup
18-25     167
26-35     175
36-45     191
46-55     191
56-65     176
65+       100
Name: count, dtype: int64
```

1.1.4-3.jpg

Made by QuadAIT

1.1.5

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# 1. 数据采集
# 从本地文件中读取数据  2分
data = pd.read_csv('vehicle_traffic_data.csv')
print("数据采集完成，已加载到DataFrame中")

# 打印数据的前5条记录 2分
print(data.head())
```

```
数据采集完成，已加载到DataFrame中
   VehicleID DriverName  Age Gender  Speed  TravelDistance   TravelTime  \
0          1    Driver_1   62   Male     17             242   854.117647
1          2    Driver_2   65   Male    128             438   205.312500
2          3    Driver_3   18   Male    167             792   284.550898
3          4    Driver_4   21   Male     38             999  1577.368421
4          5    Driver_5   21   Male    193             364   113.160622

  TrafficEvent
0       Normal
1     Accident
2    Breakdown
3  Traffic Jam
4    Breakdown
```

1.1.5-1.jpg

In [2]:
```
# 2. 数据清洗与预处理
# 处理缺失值（删除）  2分
data = data.dropna()

# 数据类型转换
data['Age'] = data['Age'].astype(int)        #Age数据类型转换为int 1分
data['Speed'] = data['Speed'].astype(float)      #Speed数据类型转换为float 1分
data['TravelDistance'] = data['TravelDistance'].astype(float)      #TravelDistance数
据类型转换为float 1分
data['TravelTime'] = data['TravelTime'].astype(float)      #TravelTime数据类型转换为f
loat 1分

# 处理异常值  2分
data = data[(data['Age'].between(18, 70))  &
            (data['Speed'].between(0, 200)) &
            (data['TravelDistance'].between(1, 1000)) &
            (data['TravelTime'].between(1, 1440))]

# 保存清洗后的数据  1分
data.to_csv('cleaned_vehicle_traffic_data.csv', index=False)
print("数据清洗完成，已保存为 'cleaned_vehicle_traffic_data.csv'")
```

```
数据清洗完成，已保存为 'cleaned_vehicle_traffic_data.csv'
```

Made by QuadAI

In [3]:
```
# 3. 数据合理性审核
# 审核字段合理性 1分
unreasonable_data = data[~((data['Age'].between(18, 70)) &
                           (data['Speed'].between(0, 200)) &
                           (data['TravelDistance'].between(1, 1000)) &
                           (data['TravelTime'].between(1, 1440)))]
print("不合理的数据:\n", unreasonable_data)

# 4. 数据统计
# 统计每种交通事件的发生次数  2分
traffic_event_counts = data['TrafficEvent'].value_counts()
print("每种交通事件的发生次数:\n", traffic_event_counts)

# 统计不同性别的平均车速、行驶距离和行驶时间  2分
gender_stats = data.groupby('Gender').agg({'Speed': 'mean', 'TravelDistance': 'mean',
    'TravelTime': 'mean'})
print("不同性别的平均车速、行驶距离和行驶时间:\n", gender_stats)

# 统计不同年龄段的驾驶员数  5分
age_bins = [18, 26, 36, 46, 56, 66, np.inf]
age_labels = ['18-25', '26-35', '36-45', '46-55', '56-65', '65+']
data['AgeGroup'] = pd.cut(data['Age'], bins=age_bins, labels=age_labels, right=Fals
e)
age_group_counts = data['AgeGroup'].value_counts()
print("不同年龄段的驾驶员数:\n", age_group_counts)
```

```
不合理的数据:
 Empty DataFrame
Columns: [VehicleID, DriverName, Age, Gender, Speed, TravelDistance, TravelTime, T
rafficEvent]
Index: []
```

1.1.5-2.jpg

```
每种交通事件的发生次数:
 TrafficEvent
Accident        229
Normal          227
Traffic Jam     218
Breakdown       204
Name: count, dtype: int64
```

1.1.5-3.jpg

```
不同性别的平均车速、行驶距离和行驶时间:
                Speed  TravelDistance  TravelTime
Gender
Female  105.130820       487.476718  359.628355
Male    108.918033       477.932084  359.134097
```

1.1.5-4.jpg

```
不同年龄段的驾驶员数:
 AgeGroup
46-55    172
36-45    169
56-65    159
26-35    154
18-25    151
65+       73
Name: count, dtype: int64
```

1.1.5-5.jpg

Made by QuadAIT

1.2.1.docx

请勿修改答题卷，在指定单元格内填写答案

1.2.1-1

顾客评价情感识别业务模块中用户反映最强烈的两个问题为：

1. 情感识别准确性不高

用户发现系统对评价的情感倾向判断不准确，导致分析结果与实际情况存在偏差。这会让用户感到不满，因为他们依赖情感识别来获取准确的用户反馈，不准确的结果会影响他们的决策。

2. 响应速度慢

用户在提交评价后，需要等待较长时间才能获得情感识别的结果。这会影响用户的使用体验，因为他们期望能够快速得到反馈，以便及时作出响应。

1.2.1-2

为优化顾客评价情感识别业务模块的方案如下：

关键实施步骤：关键步骤 4 选 3

1. 对现有的情感识别算法进行深度优化，旨在通过增加训练数据量和采用更为丰富的标注数据来训练模型，进而显著提高情感识别的准确性。

2. 优化算法的计算过程，减少计算复杂度，同时升级服务器硬件以提升整体处理能力，确保系统响应速度的大幅提升。

3. 对用户界面进行全面重新设计，确保界面简洁、直观，并增加用户引导元素，以协助用户迅速熟悉并高效使用系统。

4. 开发定制化接口，使用户能够根据实际需求调整情感识别参数，并提供领域特定的情感识别模型，以满足不同用户在特定场景下的需求。

期望的优化效果：

1. 情感识别的准确性得到显著提升，误判和漏判现象明显减少。
2. 系统响应速度得到显著加快，用户体验得到显著提升，使用户能够更快速地获取情感识别结果。
3. 用户界面设计更加友好、易用，用户操作难度降低，提升用户使用系统的便捷性和效率。
4. 提供定制化服务，满足用户特定需求，进一步提升服务质量，增强用户与系统的粘性。

Made by QuadAIT

1.2.2.docx

请勿修改答题卷，在指定单元格内填写答案

1.2.2-1

心率监测模块存在的问题包括：数据准确性受环境干扰大，异常预警响应慢，数据处理效率低。
这些问题导致老年人健康监测的实时性和准确性下降，可能影响医护人员的及时干预和老年人的健康状况，主要原因包括：数据采集和传输过程中的环境干扰，异常检测算法的不足，以及数据处理流程的不足。

1.2.2-2

优化方案包括：采用更稳定的数据采集技术，引入更精确的异常检测算法，优化数据处理流程以提高效率。

关键实施步骤包括：升级智能手环的数据采集模块，收集更多标注数据进行模型训练，优化数据处理算法和流程。协调团队资源方面，将与技术团队紧密合作，确保资源的有效分配和方案的顺利实施。

预期效果包括：提高数据准确性，加快异常预警响应速度，提升数据处理效率。

Made by QuadAIT

1.2.3.docx

请勿修改答题卷，在指定单元格内填写答案

1.2.3-1

智慧金融服务业务模块中用户反映最强烈的几个问题包括：

1. 数据准确性问题

用户发现平台提供的金融数据（如交易记录、账户余额等）与实际情况存在偏差，导致他们无法准确了解自身财务状况。这种不准确性会让用户感到困惑和不安，影响他们对平台的信任度。

2. 异常预警响应慢

当用户的金融活动出现异常时（如异常大额交易、疑似欺诈行为等）平台往往无法及时发出预警通知。这种滞后性可能让用户错过处理异常的最佳时机，导致资金损失或不必要的麻烦。

3. 服务个性化不足

用户希望平台能够根据他们的个人需求和偏好提供定制化的金融服务，但当前平台在这方面做得还不够好，缺乏个性化的服务会让用户感到平台不够贴心，无法满足他们的实际需求。

这些问题之所以会让用户感到不满，主要是因为它们直接影响了用户的使用体验和金融安全。用户期望能够得到准确、及时、个性化的金融服务，但当前平台在某些方面还未能达到这些期望。

1.2.3-2

关键实施步骤：

1. 数据准确性提升

（1）引入前沿数据采集与处理技术，以保障金融数据的实时更新与精确性。

（2）设立数据校验机制，定期执行数据比对与修正工作。

（3）提供用户反馈途径，确保用户能够及时反馈数据问题，并予以迅速修复。

2. 异常预警系统优化

（1）应用先进的机器学习算法，强化异常检测的精确度和响应速度。

（2）实施金融活动实时监控，一旦发现异常立即触发预警机制，并通过多元化渠道（包括短信、邮件、APP 推送等）向用户发送通知。

（3）建立完善的异常处理流程，确保用户在收到预警后能够得到及时的协助与指导。

3. 服务个性化提升

（1）深入分析用户行为及需求，构建详尽的用户画像。

（2）依据用户画像，提供定制化的金融产品和服务推荐。

（3）优化用户界面与交互设计，使用户能够便捷地查找并使用所需的金融服务。

期望的优化效果：

1. 显著提升金融数据的准确性，为用户提供更精确的财务状况了解途径。
2. 加快异常预警的响应速度，降低用户因异常金融活动而遭受的潜在损失。
3. 提高服务的个性化水平，增强用户对平台的亲切感与需求满足度。
4. 全面提升用户体验与服务品质，增强用户对平台的信任与忠诚度。

Made by QuadAIT

1.2.4.docx

请勿修改答题卷，在指定单元格内填写答案

1.2.4-1

智能卖点生成系统业务模块中用户反映最强烈的几个问题及解释：反映问题 4 选 3

1. 卖点生成不准确

用户反馈实例：生成的卖点与产品实际功能或特性不符，如某款手机的“超长续航”卖点实际上并不符合其电池性能。

用户不满原因：卖点无法准确反映产品优势，导致营销信息误导消费者。

影响：降低用户对产品的信任度，影响销售转化率，可能引发负面口碑。

2. 生成速度过慢

用户反馈实例：在市场急需快速推出新产品时，卖点生成系统需要数小时甚至数天才能生成满意的卖点。

用户不满原因：卖点生成过程耗时过长，无法满足快速变化的市场需求。

影响：延误产品上市时间，错失市场机会，可能被竞争对手抢占先机。

3. 缺乏个性化定制

用户反馈实例：不同市场或客户群体对同一产品的关注点不同，但系统生成的卖点却完全相同。

用户不满原因：生成的卖点过于通用，无法针对不同市场和客户群体进行个性化调整。

影响：降低营销活动的针对性和有效性，可能无法吸引特定目标群体的注意。

4. 用户界面不友好

用户反馈实例：系统操作复杂，需要多次点击和输入才能完成卖点生成，且用户界面布局混乱。

用户不满原因：系统操作不够直观易用，增加了用户的学习和使用成本。

影响：降低用户的使用体验，可能导致用户流失或减少对系统的依赖。

1.2.4-2

智能卖点生成系统优化方案：优化方案 4 选 3

1. 引入更先进的机器学习算法

实施步骤：

调研最新的自然语言处理和机器学习算法。

选择适合卖点生成的算法进行测试和验证。

集成到现有系统中，进行性能优化和调试。

期望效果：显著提高卖点与产品特性的匹配度，加快生成速度，减少用户等待时间。

2. 增加个性化定制功能

实施步骤：

设计个性化设置界面，允许用户输入目标市场和客户群体信息。

根据用户输入调整卖点生成策略，生成个性化的卖点。

进行用户测试，收集反馈，优化个性化定制功能。

期望效果：增强卖点的针对性和吸引力，提高营销活动的效果和转化率。

3. 优化用户界面和交互设计

Made by QuadAIT

实施步骤：
进行用户调研，收集关于用户界面和交互的反馈意见。
根据用户反馈重新设计用户界面和交互流程。
进行用户测试，验证新设计的易用性和用户满意度。
期望效果：降低用户学习成本，提升使用体验，增加用户对系统的满意度和忠诚度。

4. 建立持续反馈和迭代机制

实施步骤：
设立用户反馈渠道，如在线调查、用户访谈等。
定期收集和分析用户反馈，识别系统问题和改进点。
制定迭代计划，不断优化系统功能和性能。
期望效果：确保系统始终满足用户需求，保持市场竞争力，不断提升用户体验和服务质量。

Made by QuadAIT

1.2.5.docx

请勿修改答题卷，在指定单元格内填写答案

1.2.5-1

腾讯云智能数智人系统业务模块中用户反映最强烈的几个问题及解释：

1. 数智人响应不准确

用户在与数智人交互时，常常遇到数智人理解错误或回答不相关的问题，这导致用户需要多次重复或更正指令，增加了使用难度。

2. 缺乏个性化交互能力

数智人在与用户交互时，无法根据用户的个人喜好、历史交互记录等信息提供个性化的服务和建议，使得用户体验显得单调且缺乏针对性。

3. 交互流畅度不足

数智人在处理用户指令时，有时会出现延迟或卡顿现象，影响交互的实时性和流畅度，给用户带来界面设计不够友好：数智人系统的界面设计可能存在操作复杂、布局不合理等问题，导致用户在使用时感到困惑或不适。

1.2.5-2

腾讯云智能数智人系统优化方案：优化方案 4 选 3

1. 数据收集与分析

（1）详尽收集用户反馈及实际使用数据，深入剖析数智人响应不精确、个性化服务缺失等问题的根本成因。

（2）利用先进的机器学习算法对用户互动数据进行深入挖掘，以准确识别用户的实际需求和个性化偏好。

2. 模型优化与训练

（1）针对数智人响应不精确的问题，对现有自然语言处理模型进行优化升级，增强其对语义和意图的准确理解能力。

（2）引入个性化推荐算法，基于用户的历史交互记录和个性化偏好，为数智人提供更具针对性的个性化服务能力。

3. 界面与交互设计优化

（1）重新设计数智人系统的界面布局，力求简洁直观，易于用户操作和理解。

（2）优化数智人的交互流程，减少多余步骤，提升整体交互的流畅性和便捷性。

4. 测试与迭代

（1）对优化后的数智人系统进行全面严格的测试，确保各项功能稳定运行，用户体验得到显著提升。

（2）根据测试反馈及用户反馈，持续进行迭代优化，以不断提升数智人系统的性能和服务质量。

期望优化效果：

1. 数智人的响应准确性将得到显著提升，用户与数智人的交互将更为顺畅高效。
2. 数智人将具备强大的个性化服务能力，能够根据用户的个性化需求提供定制化的服务。
3. 数智人系统的界面设计将更加友好易用，用户在使用过程中将感受到更高的便捷性和舒适性。
4. 整体用户体验和服务质量将得到显著提升，用户的满意度和使用意愿将显著增加。

Made by QuadAIT

2.1.1

In [8]:
```
import pandas as pd

# 加载数据集并显示数据集的前五行 1分
data = pd.read_csv('auto-mpg.csv')
print("数据集的前五行:")
print(data.head())

# 显示每一列的数据类型
print(data.dtypes)

# 检查缺失值并删除缺失值所在的行  2分
print("\n检查缺失值:")
print(data.isnull().sum())
data = data.dropna()

# 将 'horsepower' 列转换为数值类型，并（删除）处理转换中的异常值 1分
data['horsepower'] = pd.to_numeric(data['horsepower'],errors='coerce')
data = data.dropna(subset=['horsepower'])

# 显示每一列的数据类型
print(data.horsepower.dtypes)

# 检查清洗后的缺失值
print("\n检查清洗后的缺失值:")
print(data.isnull().sum())

from sklearn.preprocessing import StandardScaler
# 对数值型数据进行标准化处理 1分
numerical_features = ['displacement', 'horsepower', 'weight', 'acceleration']
scaler = StandardScaler()
data[numerical_features] = scaler.fit_transform(data[numerical_features])

from sklearn.model_selection import train_test_split
# 选择特征、自变量和目标变量 2分
selected_features = ['cylinders', 'displacement', 'horsepower', 'weight', 'acceleration', 'model year', 'origin']
X = data[selected_features]
y = data['mpg']

# 划分数据集为训练集和测试集（训练集占8成） 1分
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)


# 将特征和目标变量合并到一个数据框中
cleaned_data = X.copy()
cleaned_data['mpg'] = y

# 保存清洗和处理后的数据（不存储额外的索引号） 1分
cleaned_data.to_csv('2.1.1_cleaned_data.csv', index=False)

# 打印消息指示文件已保存
print("\n清洗后的数据已保存到 2.1.1_cleaned_data.csv")
```

Made by QuadAIT

数据集的前五行:

```
    mpg  cylinders  displacement horsepower  weight  acceleration  model year  \
0  18.0        8.0           NaN        130  3504.0          12.0        70.0
1  15.0        8.0         350.0        165  3693.0          11.5        70.0
2  18.0        8.0         318.0        150  3436.0          11.0        70.0
3  16.0        8.0         304.0        150  3433.0          12.0        70.0
4  17.0        8.0         302.0        140  3449.0          10.5        70.0

   origin                   car name
0       1  chevrolet chevelle malibu
1       1          buick skylark 320
2       1         plymouth satellite
3       1              amc rebel sst
4       1                ford torino
mpg             float64
cylinders       float64
displacement    float64
horsepower       object
weight          float64
acceleration    float64
model year      float64
origin            int64
car name         object
dtype: object
```

检查缺失值:

```
mpg             0
cylinders       1
displacement    3
horsepower      1
weight          2
acceleration    1
model year      1
origin          0
car name        0
dtype: int64
float64
```

检查清洗后的缺失值:

```
mpg             0
cylinders       0
displacement    0
horsepower      0
weight          0
acceleration    0
model year      0
origin          0
car name        0
dtype: int64
```

清洗后的数据已保存到 2.1.1_cleaned_data.csv

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

制定数据清洗规范（每正确回答 1 个规范点得 1 分，最高得 2 分）

1. **数据加载：**使用 pandas 库加载数据集，检查数据的基本结构和类型。
2. **检查缺失值：**统计每列的缺失值数量，并删除包含缺失值的行以确保数据完整性。
3. **转换与处理异常值：**将数值列（如"horsepower"）转换为数值类型，并处理无法转换的值（例如，将其变为缺失值）。
4. **数据标准化：**对数值型数据进行标准化，以消除量纲影响，使用标准化方法。
5. **保存清洗后的数据：**将经过清洗和处理后的数据保存为新的 CSV 文件，以便后续使用。

（答对 2 点即可）

制定数据标注规范（每正确回答 1 个规范点得 1 分，最高得 3 分）

1. **数据来源：**标注数据的来源，包括数据集的名称、获取日期和数据提供者。
2. **数据描述：**提供详细的数据描述，包括每列数据的含义、单位和可能的取值范围。
3. **特征选择：**确定对目标变量预测最有用的特征。
4. **目标变量设定：**将数据集中用于预测的目标变量定义为“mpg”（燃油效率）。
5. **数据划分：**将数据分为训练集和测试集，通常采用 80/20 的比例，以便于模型的训练和评估。
6. **保存处理后的数据：**保存处理后的数据，并记录保存文件的路径和文件名。
7. **数据清洗和标注规范文档**。

（答对 3 点即可）

Made by quadAIT

2.1.2

In [4]:
```
import pandas as pd
#读取一个Excel文件，并将读取到的数据存储在变量data中
data = pd.read_excel('大学生低碳生活行为的影响因素数据集.xlsx')
#打印出数据集的前5行
print(data.head())

#处理数据集中的缺失值
initial_row_count = data.shape[0]   #处理前的数据行数
data = data.dropna()                #删除缺失值所在行
final_row_count = data.shape[0]     #处理后的数据行数
print(f'处理后数据行数: {final_row_count}, 删除的行数: {initial_row_count - final_ro
w_count}')

#删除重复行
data =  data.drop_duplicates()

from sklearn.preprocessing import StandardScaler
numerical_features = ['4.您的月生活费〇≦1,000元    〇1,001-2,000元    〇2,001-3,000元
〇≧3,001元']
scaler = StandardScaler()
data[numerical_features] = scaler.fit_transform(data[numerical_features])

#选择特征
selected_features = [ '1.您的性别〇男性    〇女性', '2.您的年级〇大一    〇大二    〇大
三    〇大四','3.您的生源地〇农村    〇城镇（乡镇）    〇地县级城市    〇省会城市及直辖市',
    '4.您的月生活费〇≦1,000元    〇1,001-2,000元    〇2,001-3,000元    〇≧3,001元',
    '5.您进行过绿色低碳的相关生活方式吗?', '6.您觉得“低碳”，与你的生活关系密切吗？',
    '7.低碳生活是否会成为未来的主流生活方式？', '8.您是否认为低碳生活会提高您的生活
质量？']
X = data[selected_features]

# 创建目标变量
y = data['低碳行为积极性']

from sklearn.model_selection import train_test_split
# 数据划分（测试集取20%）
X_train,X_test, y_train,y_test = train_test_split(X, y, test_size=0.2, random_state=42)


# 合并处理后得数据，并将其保存（保存中不用额外创建索引）
cleaned_data = pd.concat([X, y], axis=1)
cleaned_data.to_csv('2.1.2_cleaned_data.csv', index=False)
```

Made by QQGAIT

```
   序号  所用时间  1.您的性别〇男性    〇女性  2.您的年级〇大一    〇大二    〇大三    〇大四  \
0   1  130秒              1                2.0
1   2   82秒              1                2.0
2   3  230秒              1                2.0
3   4   96秒              1                2.0
4   6  157秒              1                2.0

   3.您的生源地〇农村    〇城镇（乡镇）    〇地县级城市  〇省会城市及直辖市  \
0                          2.0
1                          3.0
2                          3.0
3                          2.0
4                          1.0

   4.您的月生活费〇≦1,000元    〇1,001-2,000元    〇2,001-3,000元    〇≧3,001元  \
0                                                2.0
1                                                2.0
2                                                2.0
3                                                2.0
4                                                2.0

   5.您进行过绿色低碳的相关生活方式吗?  6.您觉得“低碳”，与你的生活关系密切吗?  7.低碳生活是否会成为未来的主流生活方式?  \
0                    1.0                  1.0                  1.0
1                    1.0                  1.0                  2.0
2                    1.0                  1.0                  2.0
3                    2.0                  2.0                  2.0
4                    1.0                  1.0                  2.0

   8.您是否认为低碳生活会提高您的生活质量?  ...  我有足够知识进行低碳生活  14.我打算以后…—减少使用一次性产品  合理处理生活中的废弃物  \
0                    2  ...                5                4                4
1                    2  ...                4                4                3
2                    3  ...                3                4                5
3                    2  ...                2                2                5
4                    2  ...                4                5                5

   在日常生活中会进行垃圾分类  尽可能劝说周围的人进行低碳生活  15.日常生活中，我会.....—对垃圾进行分类  重复利用废旧物品  \
0                3                3                3         4
1                4                5                4         3
2                3                3                3         4
3                2                2                2         2
4                5                5                5         5

   避免使用一次性产品  劝说周围的人进行低碳生活  低碳行为积极性
0           4           3         0
1           4           4         0
2           3           3         0
3           2           2         0
4           4           3         0

[5 rows x 41 columns]
处理后数据行数: 305, 删除的行数: 13
```

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

制定数据清洗规范（每正确回答 1 个规范点得 1 分，最高得 2 分）

1. **数据加载：**使用 pandas 库加载数据集，检查数据的基本结构和类型。
2. **检查缺失值：**统计每列的缺失值数量，并删除包含缺失值的行以确保数据完整性。
3. **处理重复行：**将重复的行删除。
4. **数据标准化：**对数值型数据进行标准化，以消除量纲影响，使用标准化方法。
5. **保存清洗后的数据：**将经过清洗和处理后的数据保存为新的 CSV 文件，以便后续使用。

（答对 2 点即可）

制定数据标注规范（每正确回答 1 个规范点得 1 分，最高得 3 分）

1. **数据来源：**标注数据的来源，包括数据集的名称、获取日期和数据提供者。
2. **数据描述：**提供详细的数据描述，包括每列数据的含义、单位和可能的取值范围。
3. **特征选择：**确定对目标变量预测最有用的特征。
4. **目标变量设定：**将数据集中用于预测的目标变量定义为“低碳行为积极性”。
5. **数据划分：**将数据分为训练集和测试集，通常采用 80/20 的比例，以便于模型的训练和评估。
6. **保存处理后的数据：**保存处理后的数据，并记录保存文件的路径和文件名。
7. **数据清洗和标注规范文档。**

（答对 3 点即可）

Made by QuadAI

2.1.3

In [4]:
```
import pandas as pd

# 加载数据
data = pd.read_csv('finance数据集.csv')

# 显示前五行的数据
print(data.head())

import matplotlib.pyplot as plt
import seaborn as sns

# 设置图像尺寸
plt.figure(figsize=(12, 8))

# 识别数值列用于箱线图
numeric_cols = data.select_dtypes(include=['float64', 'int64']).columns

# 创建箱线图
for i, col in enumerate(numeric_cols, 1):
    plt.subplot(3, 4, i)
    sns.boxplot(x=data[col])
    plt.title(col)

plt.tight_layout()
plt.show()

# 使用IQR处理异常值
Q1 = data[numeric_cols].quantile(0.25)
Q3 = data[numeric_cols].quantile(0.75)
IQR = Q3-Q1

# 移除异常值
data_cleaned = data[~((data[numeric_cols] < (Q1 - 1.5 * IQR)) | (data[numeric_cols]
> (Q3 + 1.5 * IQR))).any(axis=1)]

# 检查处理重复值
duplicates = data_cleaned.duplicated()
num_duplicates = duplicates.sum()
data_cleaned = data_cleaned[~duplicates]

print(f'删除的重复行数: {num_duplicates}')

#对数据进行归一化处理
from sklearn.preprocessing import MinMaxScaler

scaler = MinMaxScaler()
data_cleaned[numeric_cols] = scaler.fit_transform(data_cleaned[numeric_cols])

# 设定目标变量
target_variable = 'SeriousDlqin2yrs'

from sklearn.model_selection import train_test_split

# 定义特征和目标
X = data_cleaned.drop(columns=[target_variable])   #1分
y = data_cleaned[target_variable]                          #1分

# 划分数据（训练集占80%）
X_train, X_test, y_train,y_test = train_test_split(X,y,test_size=0.2,random_state=42)
```

Made by QuadAIT

```
# 显示划分后的数据形状
print(f'训练数据形状: {X_train.shape}')
print(f'测试数据形状: {X_test.shape}')

# 保存清洗后的数据到CSV
cleaned_file_path = '2.1.3_cleaned_data.csv'
data_cleaned.to_csv(cleaned_file_path, index=False)
```

Made by QuadAIT

	Unnamed: 0	SeriousDlqin2yrs	RevolvingUtilizationOfUnsecuredLines	age	\
0	1	1	0.766127	45	
1	2	0	0.957151	40	
2	3	0	0.658180	38	
3	4	0	0.233810	30	
4	5	0	0.907239	49	

	NumberOfTime30-59DaysPastDueNotWorse	DebtRatio	MonthlyIncome	\
0	2	0.802982	9120	
1	0	0.121876	2600	
2	1	0.085113	3042	
3	0	0.036050	3300	
4	1	0.024926	63588	

	NumberOfOpenCreditLinesAndLoans	NumberOfTimes90DaysLate	\
0	13	0	
1	4	0	
2	2	1	
3	5	0	
4	7	0	

	NumberRealEstateLoansOrLines	NumberOfTime60-89DaysPastDueNotWorse	\
0	6	0	
1	0	0	
2	0	0	
3	0	0	
4	1	0	

	NumberOfDependents
0	2
1	1
2	0
3	0
4	0

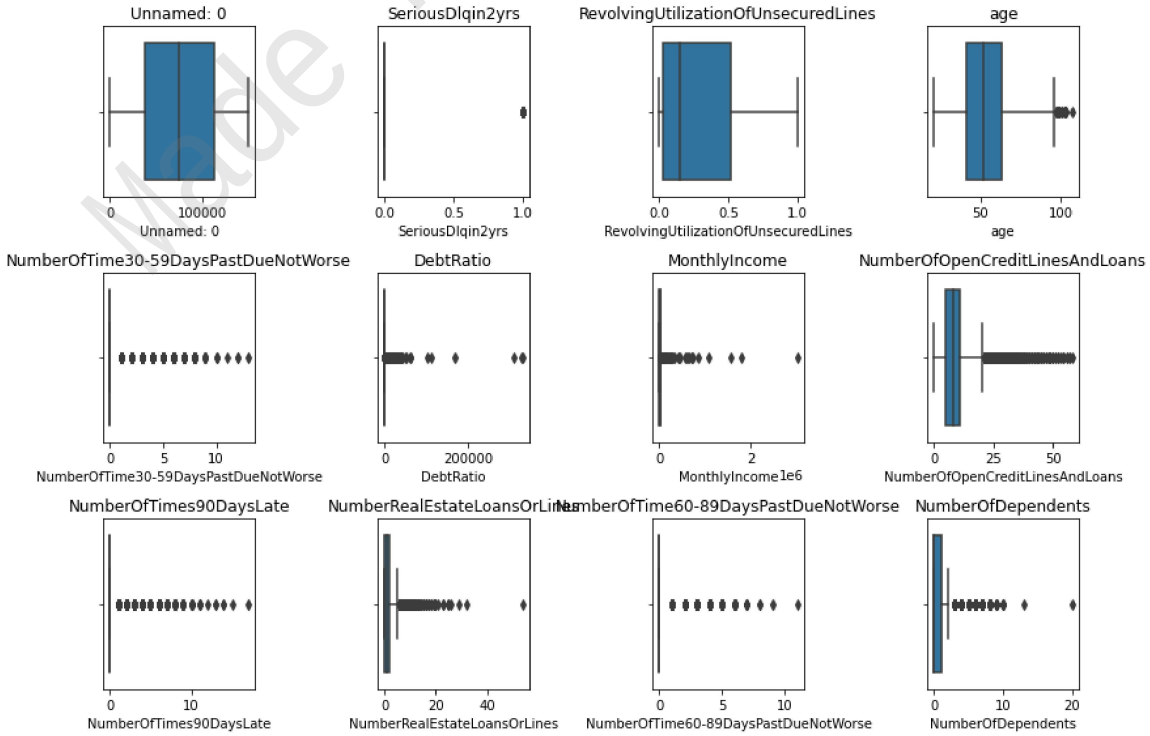

删除的重复行数：3
训练数据形状：(61105, 11)
测试数据形状：(15277, 11)

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

制定数据清洗规范（每正确回答 1 个规范点得 1 分，最高得 3 分）

1. **数据加载：**使用 pandas 库加载数据集，检查数据的基本结构和类型。
2. **异常值处理：**使用箱线图对每个数值变量进行可视化，识别潜在的异常值。
3. **重复值处理：**检查并移除数据集中的重复值，以确保数据的唯一性和完整性。
4. **数据标准化：**对数值型数据进行标准化，以消除量纲影响，使用标准化方法。
5. **保存清洗后的数据：** 将经过清洗和处理后的数据保存为新的 CSV 文件，以便后续使用。

（答对 3 点即可）

制定特征工程规范（每正确回答 1 个规范点得 1 分，最高得 2 分）

1. **数据来源：**标注数据的来源，包括数据集的名称、获取日期和数据提供者。
2. **数据描述：**提供详细的数据描述，包括每列数据的含义、单位和可能的取值范围。
3. **特征选择：**确定对目标变量预测最有用的特征。
4. **目标变量设定：**将数据集中用于预测的目标变量定义为“SeriousDlqin2yrs”。
5. **数据划分：**将数据分为训练集和测试集，通常采用 80/20 的比例，以便于模型的训练和评估。
6. **保存处理后的数据：**保存处理后的数据，并记录保存文件的路径和文件名。
7. **数据清洗和标注规范文档。**

（答对 2 点即可）

Made by quadAIT

2.1.4

In [3]:
```
import pandas as pd

# 加载数据集并指定编码为gbk
data = pd.read_csv('medical_data.csv', encoding='gbk')

# 查看数据类型
print(data.dtypes)

# 查看表结构基本信息
print(data.info())

# 显示每一列的空缺值数量
print(data.isnull().sum())

# 规范日期格式
data['就诊日期'] = pd.to_datetime(data['就诊日期'])
data['诊断日期'] = pd.to_datetime(data['诊断日期'])

# 修改列名
data.rename(columns={'病人ID': '患者ID'}, inplace=True)

# 查看修改后的表结构
print(data.head())

from datetime import datetime

# 增加诊断延迟和病程列
data['诊断延迟'] = (data['诊断日期'] - data['就诊日期']).dt.days
data['病程'] = (datetime(2024, 9, 1) - data['诊断日期']).dt.days

# 删除不合理的数据
data = data[(data['诊断延迟'] >= 0) & (data['年龄'] > 0) & (data['年龄'] < 120)]

# 查看修改后的数据
print(data.describe())

# 删除重复值并记录删除的行数
initial_rows = data.shape[0]
data.drop_duplicates(inplace=True)
deleted_rows = initial_rows - data.shape[0]

print(f'删除的重复行数: {deleted_rows}')

from sklearn.preprocessing import MinMaxScaler

# 对需要归一化的列进行处理
scaler = MinMaxScaler()
columns_to_normalize = ['年龄', '体重', '身高']
data[columns_to_normalize] = scaler.fit_transform(data[columns_to_normalize])

# 查看归一化后的数据
print(data.head())

import matplotlib.pyplot as plt
import matplotlib.font_manager as fm

# 统计治疗结果分布
treatment_outcome_distribution = data.groupby('疾病类型')['治疗结果'].value_counts
().unstack()
```

Made by QuadAIT

```
# 设置中文字体
font_path = 'C:/Windows/Fonts/simhei.ttf'  # 根据你的系统调整字体路径
my_font = fm.FontProperties(fname=font_path)

# 绘制柱状图
treatment_outcome_distribution.plot(kind='bar', stacked=True)
plt.title('不同疾病类型的治疗结果分布', fontproperties=my_font)
plt.xlabel('疾病类型', fontproperties=my_font)
plt.ylabel('治疗结果数量', fontproperties=my_font)
plt.xticks(fontproperties=my_font)  # 设置x轴刻度标签的字体
plt.yticks(fontproperties=my_font)  # 设置y轴刻度标签的字体
plt.legend(prop=my_font)  # 设置图例字体
plt.show()

# 绘制散点图
plt.scatter(data['年龄'], data['疾病严重程度'])
plt.title('年龄和疾病严重程度的关系', fontproperties=my_font)
plt.xlabel('年龄', fontproperties=my_font)
plt.ylabel('疾病严重程度', fontproperties=my_font)
plt.xticks(fontproperties=my_font)  # 设置x轴刻度标签的字体
plt.yticks(fontproperties=my_font)  # 设置y轴刻度标签的字体
plt.legend(prop=my_font)  # 设置图例字体
plt.show()

# 保存处理后得数据
output_path = '2.1.4_cleaned_data.csv'
data.to_csv(output_path, index=False)
```

Made by QuadAIT

```
病人ID        int64
年龄          int64
性别         object
地区         object
就诊日期       object
疾病类型       object
诊断日期       object
疾病严重程度     object
治疗方案       object
治疗结果       object
药物名称       object
药物分类       object
用药剂量       object
用药时长       object
检查项目       object
检查结果      float64
参考范围       object
体重         float64
身高         float64
吸烟情况       object
饮酒情况       object
遗传病史       object
dtype: object
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5440 entries, 0 to 5439
Data columns (total 22 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   病人ID    5440 non-null   int64
 1   年龄      5440 non-null   int64
 2   性别      5440 non-null   object
 3   地区      5438 non-null   object
 4   就诊日期    5439 non-null   object
 5   疾病类型    5440 non-null   object
 6   诊断日期    5429 non-null   object
 7   疾病严重程度  5439 non-null   object
 8   治疗方案    5438 non-null   object
 9   治疗结果    5437 non-null   object
 10  药物名称    5438 non-null   object
 11  药物分类    5438 non-null   object
 12  用药剂量    5436 non-null   object
 13  用药时长    5438 non-null   object
 14  检查项目    5435 non-null   object
 15  检查结果    5437 non-null   float64
 16  参考范围    5439 non-null   object
 17  体重      5437 non-null   float64
 18  身高      5439 non-null   float64
 19  吸烟情况    5437 non-null   object
 20  饮酒情况    5439 non-null   object
 21  遗传病史    5440 non-null   object
dtypes: float64(3), int64(2), object(17)
memory usage: 935.1+ KB
None
病人ID        0
年龄          0
性别          0
地区          2
就诊日期        1
疾病类型        0
诊断日期       11
疾病严重程度      1
```

made by QuadAIT

```
治疗方案        2
治疗结果        3
药物名称        2
药物分类        2
用药剂量        4
用药时长        2
检查项目        5
检查结果        3
参考范围        1
体重          3
身高          1
吸烟情况        3
饮酒情况        1
遗传病史        0
dtype: int64
    患者ID  年龄 性别  地区       就诊日期 疾病类型       诊断日期 疾病严重程度
治疗方案  治疗结果  ...  用药剂量  \
0  20413  45  女  重庆 2023-04-04   感冒 2023-04-25     不严重     放疗   病情稳定
...   每周一次
1  27375  38  女  深圳 2023-03-12   哮喘 2022-12-10     不严重     化疗     康复  ...
10毫克
2  93406  27  女  武汉 2022-11-19   哮喘 2022-10-23     不严重   物理疗法     好转
...   每日2次
3  59255  87  男  成都 2022-10-30   骨折 2022-12-14      中度     放疗   病情稳定
...   每周一次
4  52488  24  男  北京 2022-09-22  糖尿病 2022-07-10     不严重   药物治疗     好转
...   饭后服用

  用药时长  检查项目    检查结果 参考范围      体重      身高  吸烟情况  饮酒情况 遗
传病史
0  2个月    尿常规   105.0    正常    67.0  184.0      是     偶尔      是
1    1周     血压   140.0    正常    43.0  140.0     戒烟     戒酒      是
2    长期   核磁共振   175.0    未知    91.0  199.0      否     偶尔   不清楚
3    1周    胆固醇   157.0    正常    79.0  165.0      是     戒酒      是
4    3天    胆固醇    70.0    未知   119.0  158.0     戒烟      是   不清楚

[5 rows x 22 columns]
              患者ID          年龄                          就诊日期  \
count    2707.000000  2707.000000                          2707
mean    54772.932397    49.381234  2022-10-19 05:50:01.551533056
min     10012.000000     1.000000            2022-06-18 00:00:00
25%     31891.500000    25.000000            2022-08-07 00:00:00
50%     54527.000000    48.000000            2022-10-07 00:00:00
75%     76802.500000    74.000000            2022-12-17 12:00:00
max     99965.000000   100.000000            2023-06-18 00:00:00
std     26021.158215    28.614318                            NaN

                                 诊断日期          检查结果          体重
身高  \
count                            2707  2705.000000  2705.000000  2706.000000
mean   2023-02-16 13:39:44.484669440   124.300555    80.757856   169.778271
min              2022-06-22 00:00:00    50.000000    40.000000   140.000000
25%              2022-12-18 00:00:00    87.000000    61.000000   155.000000
50%              2023-03-01 00:00:00   124.000000    81.000000   170.000000
75%              2023-04-28 00:00:00   161.000000   101.000000   185.000000
max              2023-06-18 00:00:00   200.000000   120.000000   200.000000
std                              NaN    43.446248    23.363655    17.600611

             诊断延迟          病程
count  2707.000000  2707.000000
mean    120.326191   562.430735
```

Made by QuadAI

```
min        0.000000    441.000000
25%       48.000000    492.000000
50%      106.000000    550.000000
75%      183.000000    623.000000
max      357.000000    802.000000
std       86.129346     84.133081
删除的重复行数: 2
      患者ID       年龄  性别  地区       就诊日期  疾病类型       诊断日期  疾病严重
程度  治疗方案  治疗结果  ...  \
0    20413  0.444444   女   重庆  2023-04-04    感冒  2023-04-25     不严重     放疗   病情
稳定  ...
3    59255  0.868687   男   成都  2022-10-30    骨折  2022-12-14      中度     放疗   病情
稳定  ...
5    66021  0.333333   男   深圳  2022-11-03   高血压  2023-04-16     不严重     化疗
康复  ...
7    21594  0.111111   男   杭州  2022-08-07   糖尿病  2023-05-19      轻度   物理疗法   病
情稳定  ...
10   14858  0.767677   女   广州  2022-08-18   高血压  2022-11-28      严重   手术治疗   病
情稳定  ...

     检查项目    检查结果  参考范围       体重       身高  吸烟情况  饮酒情况   遗传病
史    诊断延迟      病程
0     尿常规   105.0    正常   0.3375   0.733333      是    偶尔      是    21.0   495.0
3     胆固醇   157.0    正常   0.4875   0.416667      是    戒酒      是    45.0   627.0
5    核磁共振   126.0    偏高   0.9375   0.983333      否    偶尔      否   164.0   504.0
7     尿常规    91.0    正常   0.4250   0.900000      否    否       否   285.0   471.0
10     血压    98.0    偏低   0.6250   0.116667      否    是       否   102.0   643.0

[5 rows x 24 columns]
```

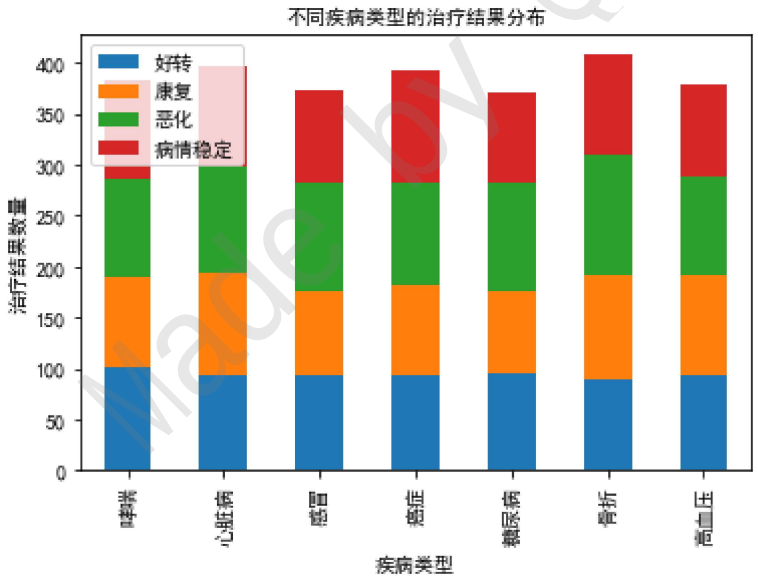


```
No handles with labels found to put in legend.
```

Made by QuadAI

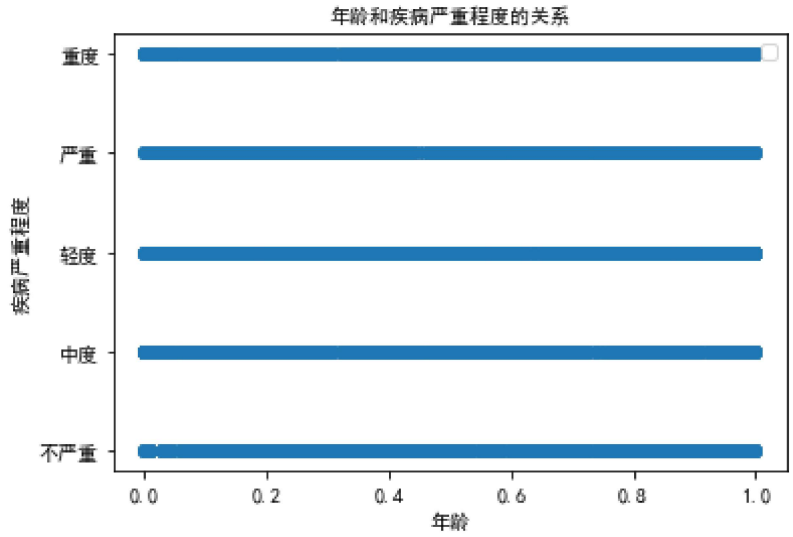

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

制定数据清洗规范（每正确回答 1 个规范点得 1 分，最高得 2 分）

1. **数据加载：**使用 pandas 库加载数据集，检查数据的基本结构和类型。
2. **数据类型和结构检查：**检查数据类型和表结构，确保各列的数据类型正确，数据结构完整。显示每列的空缺值数量，以识别缺失数据。
3. **处理日期格式：**将日期字段转换为标准日期格式 yyyy-mm-dd，确保日期字段的一致性和可读性。
4. **重命名列名：**重命名列名以提高可读性和一致性。
5. **增加计算列：**根据需要增加计算列，如“诊断延迟“和“病程”。
6. **删除不合理的数据：**删除不合理的数据记录，例如负值或异常大的值。
7. **处理缺失值：**确保数据完整性。
8. **检查并删除重复值：**检查数据集中的重复值并删除所有重复记录，记录删除的行数。
9. **数据归一化：**确保数据在相同的尺度上进行比较和分析。
10. **保存清洗后的数据：**将经过清洗和处理后的数据保存为新的 CSV 文件，以便后续使用。

（答对 2 点即可）

制定数据标注规范（每正确回答 1 个规范点得 1 分，最高得 3 分）

1. **数据来源：**标注数据的来源，包括数据集的名称、获取日期和数据提供者。
2. **数据描述：**提供详细的数据描述，包括每列数据的含义、单位和可能的取值范围。
3. **数据处理步骤：**详细记录数据处理的每一步，包括数据加载、缺失值处理、数据转换、数据归一化等操作。
4. **数据处理结果：**记录数据处理后的结果，包括空缺值填充情况、重复值删除情况和数据归一化情况。
5. **保存处理后的数据：**保存处理后的数据，并记录保存文件的路径和文件名。
6. **数据清洗和标注规范文档。**

（答对 3 点即可）

Made by QuadAIT

2.1.5

In [1]:
```
import pandas as pd

# 加载数据集
data = pd.read_csv('健康咨询客户数据集.csv')

# 查看表结构基本信息
print(data.info())

# 显示每一列的空缺值数量
print(data.isnull().sum())

# 删除含有缺失值的行
data_cleaned = data.dropna().copy()

# 转换 'Your age' 列的数据类型为整数类型，并处理异常值
data_cleaned.loc[:, 'Your age'] = pd.to_numeric(data_cleaned['Your age'], errors='coerce')
data_cleaned = data_cleaned.dropna(subset=['Your age'])
data_cleaned = data_cleaned[data_cleaned['Your age'] >= 0]
data_cleaned.loc[:, 'Your age'] = data_cleaned['Your age'].astype(int)

print(data_cleaned['Your age'].dtype)

# 检查和删除重复值
duplicates_removed = data_cleaned.duplicated().sum()
data_cleaned = data_cleaned.drop_duplicates()

print(f"Removed {duplicates_removed} duplicate rows")

from sklearn.preprocessing import LabelEncoder

# 归一化 'How do you describe your current level of fitness ?' 列
label_encoder = LabelEncoder()
data_cleaned['How do you describe your current level of fitness ?'] = label_encoder.fit_transform(data_cleaned['How do you describe your current level of fitness ?'])

print(data_cleaned['How do you describe your current level of fitness ?'].unique())

from sklearn.preprocessing import LabelEncoder
import matplotlib.pyplot as plt

# 去掉列名中的空格
data.columns = data.columns.str.strip()
# 显示数据集的列名
print(data.columns)

# 删除包含缺失值的行
data_cleaned = data.dropna(subset=['How often do you exercise?'])

# 统计不同健身频率的分布情况
exercise_frequency_counts = data_cleaned['How often do you exercise?'].value_counts()

# 绘制饼图
plt.figure(figsize=(10, 6))
exercise_frequency_counts.plot.pie(autopct='%1.1f%%', startangle=90, colors=plt.cm.Paired.colors)
plt.title('Distribution of Exercise Frequency')
plt.ylabel('')
plt.show()
```

Made by QuadAIT

```
import pandas as pd
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt

# 填充缺失值
data_filled = data.apply(lambda x: x.fillna(x.mode()[0]))

# 划分数据（测试集占比20%）
train_data, test_data = train_test_split(data_filled, test_size=0.2, random_state=4
2)

# 保存处理后的数据
cleaned_file_path = '2.1.5_cleaned_data.csv'
data_filled.to_csv(cleaned_file_path, index=False)
```

Made by QuadAIT

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 551 entries, 0 to 550
Data columns (total 18 columns):
 #   Column
Non-Null Count  Dtype
---  ------
--------------  -----
 0   Timestamp
551 non-null    object
 1   Your name
551 non-null    object
 2   Your gender
551 non-null    object
 3   Your age
551 non-null    object
 4   How important is exercise to you ?
551 non-null    int64
 5   How do you describe your current level of fitness ?
551 non-null    object
 6   How often do you exercise?
550 non-null    object
 7   What barriers, if any, prevent you from exercising more regularly?
(Please select all that apply)            551 non-null    object
 8   What form(s) of exercise do you currently participate in ?
(Please select all that apply)       550 non-null    object
 9   Do you exercise __________ ?
549 non-null    object
 10  What time if the day do you prefer to exercise?
551 non-null    object
 11  How long do you spend exercising per day ?
551 non-null    object
 12  Would you say you eat a healthy balanced diet ?
550 non-null    object
 13  What prevents you from eating a healthy balanced diet, If any?
(Please select all that apply)  551 non-null    object
 14  How healthy do you consider yourself?
550 non-null    float64
 15  Have you ever recommended your friends to follow a fitness routine?
550 non-null    object
 16  Have you ever purchased a fitness equipment?
551 non-null    object
 17  What motivates you to exercise?         (Please select all that applies )
551 non-null    object
dtypes: float64(1), int64(1), object(16)
memory usage: 77.6+ KB
None
Timestamp
0
Your name
0
Your gender
0
Your age
0
How important is exercise to you ?
0
How do you describe your current level of fitness ?
0
How often do you exercise?
1
What barriers, if any, prevent you from exercising more regularly?           (Plea
```

Made by QuadAIT

```
se select all that apply)              0
What form(s) of exercise do you currently participate in ?
(Please select all that apply)         1
Do you exercise __________ ?
2
What time if the day do you prefer to exercise?
0
How long do you spend exercising per day ?
0
Would you say you eat a healthy balanced diet ?
1
What prevents you from eating a healthy balanced diet, If any?
(Please select all that apply)    0
How healthy do you consider yourself?
1
Have you ever recommended your friends to follow a fitness routine?
1
Have you ever purchased a fitness equipment?
0
What motivates you to exercise?         (Please select all that applies )
0
dtype: int64
object
Removed 0 duplicate rows
[]
Index(['Timestamp', 'Your name', 'Your gender', 'Your age',
       'How important is exercise to you ?',
       'How do you describe your current level of fitness ?',
       'How often do you exercise?',
       'What barriers, if any, prevent you from exercising more regularly?
(Please select all that apply)',
       'What form(s) of exercise do you currently participate in ?
(Please select all that apply)',
       'Do you exercise __________ ?',
       'What time if the day do you prefer to exercise?',
       'How long do you spend exercising per day ?',
       'Would you say you eat a healthy balanced diet ?',
       'What prevents you from eating a healthy balanced diet, If any?
(Please select all that apply)',
       'How healthy do you consider yourself?',
       'Have you ever recommended your friends to follow a fitness routine?',
       'Have you ever purchased a fitness equipment?',
       'What motivates you to exercise?         (Please select all that applies
)'],
      dtype='object')
```

Made by QuadAIT

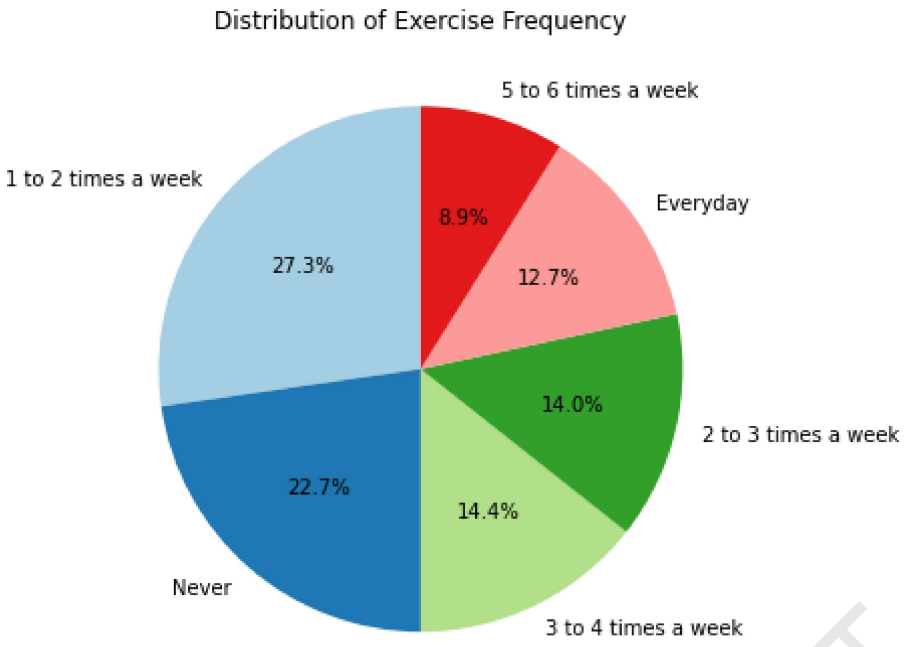

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

制定数据清洗规范（每正确回答 1 个规范点得 1 分，最高得 2 分）

数据清洗规范

1. **数据加载：**使用 pandas 库加载数据集，检查数据的基本结构和类型。
2. **检查缺失值：**统计每列的缺失值数量，并删除包含缺失值的行以确保数据完整性。
3. **转换与处理异常值：**将 *'Your age'* 列转换为整数类型，并处理无法转换的值。
4. **数据去重：**检查数据集中的重复值并删除所有重复值，记录删除的行数。
5. **数据归一化：**以消除量纲影响，使用归一化方法。
6. **保存清洗后的数据：**将经过清洗和处理后的数据保存为新的 CSV 文件，以便后续使用。

（答对 2 点即可）

制定数据标注规范（每正确回答 1 个规范点得 1 分，最高得 3 分）

1. **数据来源：**标注数据的来源，包括数据集的名称、获取日期和数据提供者。
2. **数据描述：**提供详细的数据描述，包括每列数据的含义、单位和可能的取值范围
3. **归一化处理：**使用`LabelEncoder` 对 "How do you describe your current level of fitness ?` 列进行编码。
4. **统计分析：**统计不同健身频率的分布情况，并使用饼图可视化。
5. **统计分析：**统计不同饮食习惯人群的体质指数(BMI)均值，并使用柱状图可视化。
6. **保存处理后的数据：**保存处理后的数据，并记录保存文件的路径和文件名。
7. **数据清洗和标注规范文档。**

（答对 3 点即可）

Made by QuduAIT

2.2.1

In [1]:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
import pickle
from sklearn.metrics import classification_report
from imblearn.over_sampling import SMOTE

# 加载数据
data = pd.read_csv('finance数据集.csv')

# 显示前五行的数据
print(data.head())

# 选择自变量和因变量
X = data.drop(['SeriousDlqin2yrs', 'Unnamed: 0'], axis=1)
y = data['SeriousDlqin2yrs']

# 分割训练集和测试集（测试集20%）
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_stat
e=42)

# 训练Logistic回归模型（最大迭代次数为1000次）
model = LogisticRegression(max_iter=1000)
#训练 Logistic 回归模型
model.fit(X_train, y_train)

# 保存模型
with open('2.2.1_model.pkl', 'wb') as file:
    pickle.dump(model, file)

# 预测并保存结果
y_pred = model.predict(X_test)
pd.DataFrame(y_pred, columns=['预测结果']).to_csv('2.2.1_results.txt', index=False)

# 生成测试报告
report = classification_report(y_test, y_pred, zero_division=1)
with open('2.2.1_report.txt', 'w') as file:
    file.write(report)

# 分析测试结果
accuracy = (y_test==y_pred).mean()
print(f"模型准确率: {accuracy:.2f}")

# 处理数据不平衡
smote = SMOTE(random_state=42)
X_resampled, y_resampled = smote.fit_resample(X_train, y_train)

# 重新训练模型
model.fit(X_resampled, y_resampled)
# 重新预测
y_pred_resampled = model.predict(X_test)

# 保存新结果
pd.DataFrame(y_pred_resampled, columns=['预测结果']).to_csv('2.2.1_results_xg.txt',
index=False)

# 生成新的测试报告
report_resampled = classification_report(y_test, y_pred_resampled, zero_division=1)
with open('2.2.1_report_xg.txt', 'w') as file:
    file.write(report_resampled)
```

Made by QuadAI

```
# 分析新的测试结果
accuracy_resampled = (y_test== y_pred_resampled).mean()
print(f"重新采样后的模型准确率: {accuracy_resampled:.2f}")
```

```
   Unnamed: 0  SeriousDlqin2yrs  RevolvingUtilizationOfUnsecuredLines  age  \
0           1                 1                              0.766127   45
1           2                 0                              0.957151   40
2           3                 0                              0.658180   38
3           4                 0                              0.233810   30
4           5                 0                              0.907239   49

   NumberOfTime30-59DaysPastDueNotWorse  DebtRatio  MonthlyIncome  \
0                                     2   0.802982         9120.0
1                                     0   0.121876         2600.0
2                                     1   0.085113         3042.0
3                                     0   0.036050         3300.0
4                                     1   0.024926        63588.0

   NumberOfOpenCreditLinesAndLoans  NumberOfTimes90DaysLlate  \
0                               13                         0
1                                4                         0
2                                2                         1
3                                5                         0
4                                7                         0

   NumberRealEstateLoansOrLines  NumberOfTime60-89DaysPastDueNotWorse  \
0                             6                                     0
1                             0                                     0
2                             0                                     0
3                             0                                     0
4                             1                                     0

   NumberOfDependents
0                 2.0
1                 1.0
2                 0.0
3                 0.0
4                 0.0
模型准确率: 0.94
重新采样后的模型准确率: 0.75
```

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

针对 Logistic 模型（以下三题各 1 分）

1、模型性能（答案在 report.txt 文件中）

	precision	recall	f1-score	support
0（没有严重逾期）	0.95	0.99	0.97	26779
1（有严重逾期）	0.58	0.14	0.23	1737

2、错误分析

0(没有严重逾期)：
准确率很高，召回率也很高，表明模型在这一类别上的性能非常好，
可能的错误主要来自于少数漏报情况，即极少数实际没有严重逾期的样本被错误预测为有严重逾期。

1(有严重逾期)：
准确率较低，召回率也很低，F1-Score 仅为 0.23，表明模型在这一类别上的性能较差。
主要问题在于大量的漏报(真正有严重逾期的样本被预测为没有)和一定的误报(将没有严重逾期的样本预测为有)。

3、改进建议

1.数据处理策略调整
重采样技术：由于数据集存在明显的不平衡，可以考虑使用过采样(如 SMOTE)或欠采样技术来平衡两个类别的数量。
2.特征工程优化
特征选择：仔细审查现有特征，去除冗余或不相关的特征，可能有助于提升模型性能。
特征构造：尝试创建新的、更具区分力的特征，如基于现有特征的交互项或衍生指标。

Made by QuadIT

2.2.2

In [2]:
```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
import pickle
from sklearn.ensemble import RandomForestRegressor

# 加载数据集
df = pd.read_csv('auto-mpg.csv')

# 显示前五行数据
print(df.head())

# 处理缺失值
# 将 'horsepower' 列中的所有值转换为数值类型
df['horsepower'] = pd.to_numeric(df['horsepower'], errors='coerce')
# 删除包含缺失值的行
df = df.dropna()

# 选择相关特征进行建模（定义自变量（返回一个DataFrame）和因变量）
X = df[['cylinders', 'displacement', 'horsepower', 'weight', 'acceleration', 'model year', 'origin']]
y = df['mpg']

# 将数据集划分为训练集和测试集（测试集占比20%）
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 创建包含标准化和线性回归的管道
pipeline = Pipeline([('scaler', StandardScaler()),('linreg', LinearRegression())])

# 训练模型
pipeline.fit(X_train, y_train)

# 保存训练好的模型
with open('2.2.2_model.pkl', 'wb') as model_file:
    pickle.dump(pipeline, model_file)

# 预测并保存结果
y_pred = pipeline.predict(X_test)
results_df = pd.DataFrame(y_pred, columns=['预测结果'])
results_df.to_csv('2.2.2_results.txt', index=False)

# 测试模型
with open('2.2.2_report.txt', 'w') as results_file:
    results_file.write(f'训练集得分: {pipeline.score(X_train, y_train)}\n')
    results_file.write(f'测试集得分: {pipeline.score(X_test, y_test)}\n')

# 创建随机森林回归模型实例（创建的决策树的数量为100）
rf_model = RandomForestRegressor(n_estimators=100, random_state=42)
# 训练随机森林回归模型
rf_model.fit(X_train, y_train)

# 使用随机森林模型进行预测
y_pred_rf = rf_model.predict(X_test)

# 保存新的结果
results_rf_df = pd.DataFrame(y_pred_rf, columns=['预测结果'])
results_rf_df.to_csv('2.2.2_results_rf.txt', index=False)
```

Made by QuadAIT

```
# 测试模型并保存得分
with open('2.2.2_report_rf.txt', 'w') as results_rf_file:
    results_rf_file.write(f'训练集得分: {rf_model.score(X_train, y_train)}\n')
    results_rf_file.write(f'测试集得分: {rf_model.score(X_test, y_test)}\n')
```

```
    mpg  cylinders  displacement horsepower  weight  acceleration  model year  \
0  18.0          8         307.0        130    3504          12.0          70
1  15.0          8         350.0        165    3693          11.5          70
2  18.0          8         318.0        150    3436          11.0          70
3  16.0          8         304.0        150    3433          12.0          70
4  17.0          8         302.0        140    3449          10.5          70

   origin                   car name
0       1  chevrolet chevelle malibu
1       1          buick skylark 320
2       1         plymouth satellite
3       1              amc rebel sst
4       1                ford torino
```

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

针对线性回归模型（以下三题各 1 分）

1、模型性能（答案在 report.txt 文件中）

训练集得分	0.826001578671067
测试集得分	0.7901500386760345

2、错误分析

1.过拟合：训练集得分略高于测试集得分，可能存在轻微的过拟合现象。这意味着模型在训练数据上表现良好，但在未见过的数据上表现稍差。
2.待征工程：当前使用的特征可能没有完全捕捉到影响目标变量的所有重要信息。可以考虑添加更多相关特征或进行特征变换。
3.模型选择：线性回归模型可能不是最适合这个问题的模型。可以尝试其他更复杂的模型，如支持向量机、神经网络或集成方法(如随机森林、梯度提升机)。

3、改进建议

1.特征工程：
探索数据集，寻找更多潜在的特征。
对现有特征进行变换，如对数变换、多项式特征等。
使用特征选择方法减少冗余特征。
2.模型选择与调参：
尝试不同的模型，如随机森林、梯度提升机或神经网络。
使用交叉验证来评估模型性能，避免过拟合。
对选定模型进行超参数调优，以找到最佳参数组合。

Made by QiaoIT

2.2.3

In [1]:
```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
import pickle
from sklearn.metrics import mean_squared_error, r2_score
import xgboost as xgb

# 加载数据集
df = pd.read_csv('fitness analysis.csv')

# 显示前五行数据
print(df.head())

# 去除所有字符串字段的前后空格
df = df.applymap(lambda x: x.strip() if isinstance(x, str) else x)

# 检查和清理列名
df.columns = df.columns.str.strip()

# 选择相关特征进行建模
X = df[['Your gender', 'How important is exercise to you ?', 'How healthy do you con
sider yourself?']]
X = pd.get_dummies(X)  # 将分类变量转为数值变量

# 将年龄段转为数值变量
y = df['Your age'].apply(lambda x: int(x.split(' ')[0]))  # 假设年龄段为整数

# 将数据集划分为训练集和测试集（测试集占比20%）
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.2, random_state=
42)

# 创建随机森林回归模型（创建的决策树的数量为100）
rf_model = RandomForestRegressor(n_estimators=100, random_state=42)
# 训练随机森林回归模型
rf_model.fit(X_train,y_train)

# 保存训练好的模型
with open('2.2.3_model.pkl', 'wb') as model_file:
    pickle.dump(rf_model,model_file)

# 进行结果预测
y_pred = rf_model.predict(X_test)
results_df = pd.DataFrame(y_pred, columns=['预测结果'])
results_df.to_csv('2.2.3_results.txt', index=False)

# 使用测试工具对模型进行测试，并记录测试结果
train_score = rf_model.score(X_train,y_train)   #训练集分数
test_score = rf_model.score(X_test, y_test)    #测试集分数
mse = mean_squared_error(y_test,y_pred)  #均方误差
r2 = r2_score(y_test,y_pred)  #决定系数
with open('2.2.3_report.txt', 'w') as report_file:
    report_file.write(f'训练集得分: {train_score}\n')
    report_file.write(f'测试集得分: {test_score}\n')
    report_file.write(f'均方误差(MSE): {mse}\n')
    report_file.write(f'决定系数(R^2): {r2}\n')

# 运用工具分析算法中错误案例产生的原因并进行纠正
# 初始化XGBoost回归模型（构建100棵树）
xgb_model = xgb.XGBRegressor(n_estimators=100, random_state=42)
# 训练XGBoost回归模型
```

Made by QuadAIT

```
xgb_model.fit(X_train,y_train)
# 使用XGBoost回归模型在测试集上进行结果预测
y_pred_xgb = xgb_model.predict(X_test)

results_df_xgb = pd.DataFrame(y_pred_xgb, columns=['预测结果'])
results_df_xgb.to_csv('2.2.3_results_xgb.txt', index=False)

with open('2.2.3_report_xgb.txt', 'w') as xgb_report_file:
    xgb_report_file.write(f'XGBoost训练集得分: {xgb_model.score(X_train,y_train)}
\n')
    xgb_report_file.write(f'XGBoost测试集得分: {xgb_model.score(X_test, y_test)}\n')
    xgb_report_file.write(f'XGBoost均方误差(MSE): {mean_squared_error(y_test,y_pred_
xgb)}\n')
    xgb_report_file.write(f'XGBoost决定系数(R^2): {r2_score(y_test,y_pred_xgb)}\n')
```

Made by QuadAIT

```
                          Timestamp Your name  Your gender  Your age   \
0  2019/07/03 11:48:07 PM GMT+5:30    Parkavi       Female  19 to 25
1  2019/07/03 11:51:22 PM GMT+5:30   Nithilaa       Female  19 to 25
2  2019/07/03 11:56:28 PM GMT+5:30  Karunya v       Female  15 to 18
3   2019/07/04 5:43:35 AM GMT+5:30    Anusha        Female  15 to 18
4   2019/07/04 5:44:29 AM GMT+5:30   Nikkitha       Female  19 to 25

   How important is exercise to you ?  \
0                                   2
1                                   4
2                                   3
3                                   4
4                                   3

  How do you describe your current level of fitness ?  \
0                                              Good
1                                         Very good
2                                              Good
3                                              Good
4                                             Unfit

  How often do you exercise?  \
0                      Never
1                      Never
2       1 to 2 times a week
3       3 to 4 times a week
4                      Never

  What barriers, if any, prevent you from exercising more regularly?           (Pl
ease select all that apply)  \
0    I don't have enough time;I can't stay motivated
1     I don't have enough time;I'll become too tired
2                           I can't stay motivated
3                        I don't have enough time
4                           I can't stay motivated

  What form(s) of exercise do you currently participate in ?
(Please select all that apply)  \
0                           I don't really exercise
1                    Walking or jogging;Swimming
2                                Walking or jogging
3          Walking or jogging;Gym;Lifting weights
4                           I don't really exercise

  Do you exercise _____ ?  \
0      I don't really exercise
1                 With a group
2                        Alone
3                        Alone
4      I don't really exercise

  What time if the day do you prefer to exercise?  \
0                                  Early morning
1                                  Early morning
2                                  Early morning
3                                        Evening
4                                        Evening

  How long do you spend exercising per day ?  \
0                  I don't really exercise
1                  I don't really exercise
```

Made by QuadAIT

```
2                                30 minutes
3                                   1 hour
4                  I don't really exercise

  Would you say you eat a healthy balanced diet ?  \
0                                    Not always
1                                    Not always
2                                    Not always
3                                           Yes
4                                           Yes

  What prevents you from eating a healthy balanced diet, If any?
(Please select all that apply)  \
0  Ease of access to fast food;Temptation and cra...
1  Ease of access to fast food;Temptation and cra...
2                          Temptation and cravings
3                          Temptation and cravings
4  Ease of access to fast food;Temptation and cra...

   How healthy do you consider yourself?  \
0                                    3
1                                    4
2                                    4
3                                    4
4                                    4

  Have you ever recommended your friends to follow a fitness routine?  \
0                                                 Yes
1                                                 Yes
2                                                 Yes
3                                                 Yes
4                                                 Yes

  Have you ever purchased a fitness equipment?  \
0                                          No
1                                          No
2                                         Yes
3                                          No
4                                          No

  What motivates you to exercise?         (Please select all that applies )
0  I'm sorry ... I'm not really interested in exe...
1  I want to be fit;I want to be flexible;I want ...
2                               I want to be fit
3          I want to be fit;I want to lose weight
4                               I want to be fit
```

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

针对随机森林模型（以下三题各 1 分）

1、模型性能（答案在 report.txt 文件中）

训练集得分	0.12387053768702816
测试集得分	-0.09219954290443844
均方误差（MSE）	109.76692738027478
决定系数（R^2）	-0.09219954290443844

2、错误分析

1.过拟合：模型在训练集上的得分较高，而在测试集上的得分较低，这表明模型可能过拟合了训练数据，即模型学到了训练数据中的噪声而不是潜在的模式。
2.特征不足：所选特征可能不足以捕捉到年龄与所选特征之间的复杂关系。只有三个特征(性别、锻炼的重要性、自我感觉的健康程度)可能不足以全面地描述年龄的变化规律。
3.数据量或质量：数据集可能较小或存在质量问题，比如异常值、缺失值等问题，影响了模型的泛化能力。

3、改进建议

1.特征工程：
增加更多相关特征：可以从原始数据中提取更多有用的特征，比如锻炼频率、饮食习惯等。
特征选择：使用特征选择技术来确定哪些特征对于预测最有帮助。
特征构造：创建新的特征组合，比如将多个特征结合起来形成更有意义的衍生特征。
2.模型选择与调参：
调整模型参数：通过网格搜索或随机搜索调整随机森林的参数，比如 n_estimators、max_depth 等。
尝试其他模型：可以考虑使用其他回归模型，如支持向量机(SVM)、梯度提升树(如 XGBoost)等。

Made by QuadAIT

2.2.4

In [1]:
```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
import joblib
from xgboost import XGBRegressor

# 加载数据集
data = pd.read_excel('大学生低碳生活行为的影响因素数据集.xlsx')

# 显示数据集的前五行
print(data.head())

# 删除不必要的列并处理分类变量
data_cleaned = data.drop(columns=['序号', '所用时间'])  # 删除不必要的列
data_cleaned = pd.get_dummies(data_cleaned, drop_first=True)  # 将分类变量转换为哑变量/指示变量

# 定义目标变量和特征
target = '5.您进行过绿色低碳的相关生活方式吗?'  # 确保这是目标变量

# 定义自变量和因变量
X = data_cleaned.drop(columns=[target])
y = data_cleaned[target]

# 将数据拆分为训练集和测试集（测试集占20%）
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.2, random_state=42)

# 初始化线性回归模型
model = LinearRegression()
# 训练线性回归模型
model.fit(X_train, y_train)

# 保存训练好的模型
model_filename = '2.2.4_model.pkl'
joblib.dump(model,model_filename)

# 进行预测
y_pred = model.predict(X_test)

# 将结果保存到文本文件中
results = pd.DataFrame({'实际值': y_test, '预测值': y_pred})
results_filename = '2.2.4_results.txt'
results.to_csv(results_filename, index=False, sep='\t')  # 使用制表符分隔值保存到文本文件

# 将测试结果保存到报告文件中
report_filename = '2.2.4_report.txt'
with open(report_filename, 'w') as f:
    f.write(f'均方误差: {mean_squared_error(y_test,y_pred)}\n')
    f.write(f'决定系数: {r2_score(y_test,y_pred)}\n')

# 分析并纠正错误（示例：使用XGBoost）
# 初始化XGBoost模型（设定树的数量为1000，学习率为0.05，每棵树的最大深度为5，）
xgb_model = XGBRegressor(n_estimators=1000,learning_rate=0.05,max_depth=5, subsample=0.8, colsample_bytree=0.8)
# 训练XGBoost模型
xgb_model.fit(X_train, y_train)
```

Made by QuadAIT

```
# 使用XGBoost模型进行预测
y_pred_xg = xgb_model.predict(X_test)

# 将XGBoost结果保存到文本文件中
results_xg_filename = '2.2.4_results_xg.txt'
results_xg = pd.DataFrame({'实际值': y_test, '预测值': y_pred_xg})
results_xg.to_csv(results_xg_filename, index=False, sep='\t')  # 使用制表符分隔值保存到文本文件

# 将XGBoost测试结果保存到报告文件中
report_filename_xgb = '2.2.4_report_xgb.txt'
with open(report_filename_xgb, 'w') as f:
    f.write(f'均方误差: {mean_squared_error(y_test,y_pred_xg)}\n')
    f.write(f'决定系数: {r2_score(y_test,y_pred_xg)}\n')
```

Made by QuadAIT

	序号	所用时间	1.您的性别〇男性	〇女性	2.您的年级〇大一	〇大二	〇大三 〇大四 \
0	1	130秒	1		2		
1	2	82秒	1		2		
2	3	230秒	1		2		
3	4	96秒	1		2		
4	6	157秒	1		2		

	3.您的生源地〇农村	〇城镇（乡镇）	〇地县级城市	〇省会城市及直辖市 \
0			2	
1			3	
2			3	
3			2	
4			1	

	4.您的月生活费〇≦1,000元	〇1,001-2,000元	〇2,001-3,000元	〇≧3,001元 \
0			2	
1			2	
2			2	
3			2	
4			2	

	5.您进行过绿色低碳的相关生活方式吗?	6.您觉得“低碳”，与你的生活关系密切吗?	7.低碳生活是否会成为未来的主流生活方式? \
0	1	1	1
1	1	1	2
2	1	1	2
3	2	2	2
4	1	1	2

	8.您是否认为低碳生活会提高您的生活质量?	...	我有机会执行低碳生活	我有足够知识进行低碳生活	14.我打算以后…—减少使用一次性产品 \
0	2	...	5	5	4
1	2	...	5	4	4
2	3	...	3	3	4
3	2	...	2	2	2
4	2	...	5	4	5

	合理处理生活中的废弃物	在日常生活中会进行垃圾分类	尽可能劝说周围的人进行低碳生活	15.日常生活中，我会.....—对垃圾进行分类 \
0	4	3	3	3
1	3	4	5	4
2	5	3	3	3
3	5	2	2	2
4	5	5	5	5

	重复利用废旧物品	避免使用一次性产品	劝说周围的人进行低碳生活
0	4	4	3
1	3	4	4
2	4	3	3
3	2	2	2
4	5	4	3

[5 rows x 40 columns]

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

针对线性回归模型（以下三题各 1 分）

1、模型性能（答案在 report.txt 文件中）

均方误差（MSE）	0.024679563713426132
决定系数（R^2）	0.18477828249843997

2、错误分析

1.模型适用性：线性回归模型假设特征与目标变量之间存在线性关系。如果这种假设不成立，模型可能会表现不佳。
2.欠拟合：R^2 值接近于零，表明模型可能欠拟合，即模型未能很好地捕捉到数据中的模式。这也可能是因为特征的选择不够充分或者特征之间的关系不是线性的。
3.特征选择：当前模型仅使用了部分特征，并且这些特征可能未能充分描述目标变量“5,您进行过绿色低碳的相关生活方式吗?”的变化情况。
4.数据质量和数量：数据可能存在质量问题，如异常值、缺失值等，或者数据量不足，无法提供足够的信息来训练一个有效的模型。

3、改进建议

1.特征工程：
增加特征：重新审视数据集，添加更多可能影响目标变量的因素作为特征
特征选择：使用特征选择技术（如递归特征消除 RFE、基于模型的特征重要性等）来识别最相关的特征
持征构造：创建新的特征，如交互项、多项式特征等，以捕捉更复杂的非线性关系。
2.模型选择与调参：
尝试其他模型：线性回归假设特征与目标之间存在线性关系。如果这种关系不存在，可以尝试其他非线性模型，如决策树、随机森林、支持向量机(SVM)等。
调整模型参数：通过网格搜索或随机搜索调整模型的超参数，找到最优参数组合。

Made by QuadAIT

2.2.5

In [1]:
```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeRegressor
import pickle
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

# 加载数据集
df = pd.read_csv('fitness analysis.csv')

# 显示前五行数据
print(df.head())

# 选择相关特征进行建模
X = df[['Your gender ', 'How important is exercise to you ?', 'How healthy do you co
nsider yourself?']]
X = pd.get_dummies(X)  # 将分类变量转为数值变量

# 设置目标变量
y = df['daily_steps']

# 将数据集划分为训练集和测试集（测试集占20%）
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.2, random_state=
42)

# 创建并训练决策树回归模型
dt_model = DecisionTreeRegressor(random_state=42)
# 训练决策树回归模型
dt_model.fit(X_train, y_train)

# 保存训练好的模型
with open('2.2.5_model.pkl', 'wb') as model_file:
    pickle.dump(dt_model,model_file)

# 进行预测
y_pred = dt_model.predict(X_test)

# 将结果保存到文本文件中
results = pd.DataFrame({'实际值': y_test, '预测值': y_pred})
results_filename = '2.2.5_results.txt'
results.to_csv(results_filename, index=False, sep='\t')

# 将测试结果保存到报告文件中
report_filename = '2.2.5_report.txt'
with open(report_filename,'w') as f:
    f.write(f'均方误差: {mean_squared_error(y_test,y_pred)}\n')
    f.write(f'平均绝对误差: {mean_absolute_error(y_test,y_pred)}\n')
    f.write(f'决定系数: {r2_score(y_test,y_pred)}\n')
```

Made by QuadAIT

```
                          Timestamp Your name  Your gender  Your age   \
0  2019/07/03 11:48:07 PM GMT+5:30    Parkavi       Female  19 to 25
1  2019/07/03 11:51:22 PM GMT+5:30   Nithilaa       Female  19 to 25
2  2019/07/03 11:56:28 PM GMT+5:30  Karunya v       Female  15 to 18
3   2019/07/04 5:43:35 AM GMT+5:30     Anusha       Female  15 to 18
4   2019/07/04 5:44:29 AM GMT+5:30   Nikkitha       Female  19 to 25

   How important is exercise to you ?  \
0                                   2
1                                   4
2                                   3
3                                   4
4                                   3

  How do you describe your current level of fitness ?  \
0                                          Good
1                                     Very good
2                                          Good
3                                          Good
4                                        Unfit

  How often do you exercise?  \
0                      Never
1                      Never
2       1 to 2 times a week
3       3 to 4 times a week
4                      Never

  What barriers, if any, prevent you from exercising more regularly?           (Pl
ease select all that apply)  \
0    I don't have enough time;I can't stay motivated
1     I don't have enough time;I'll become too tired
2                           I can't stay motivated
3                        I don't have enough time
4                           I can't stay motivated

  What form(s) of exercise do you currently participate in ?
(Please select all that apply)  \
0                           I don't really exercise
1                     Walking or jogging;Swimming
2                                Walking or jogging
3          Walking or jogging;Gym;Lifting weights
4                           I don't really exercise

  Do you exercise _____ ?  \
0      I don't really exercise
1                 With a group
2                        Alone
3                        Alone
4      I don't really exercise

  What time if the day do you prefer to exercise?  \
0                                  Early morning
1                                  Early morning
2                                  Early morning
3                                        Evening
4                                        Evening

  How long do you spend exercising per day ?  \
0                   I don't really exercise
1                   I don't really exercise
```

Made by QuadAIT

```
2                                30 minutes
3                                    1 hour
4                  I don't really exercise

  Would you say you eat a healthy balanced diet ?  \
0                                    Not always
1                                    Not always
2                                    Not always
3                                           Yes
4                                           Yes

  What prevents you from eating a healthy balanced diet, If any?
(Please select all that apply)  \
0  Ease of access to fast food;Temptation and cra...
1  Ease of access to fast food;Temptation and cra...
2                          Temptation and cravings
3                          Temptation and cravings
4  Ease of access to fast food;Temptation and cra...

   How healthy do you consider yourself?  \
0                                     3
1                                     4
2                                     4
3                                     4
4                                     4

  Have you ever recommended your friends to follow a fitness routine?  \
0                                                 Yes
1                                                 Yes
2                                                 Yes
3                                                 Yes
4                                                 Yes

  Have you ever purchased a fitness equipment?  \
0                                        No
1                                        No
2                                       Yes
3                                        No
4                                        No

  What motivates you to exercise?         (Please select all that applies )  \
0  I'm sorry ... I'm not really interested in exe...
1  I want to be fit;I want to be flexible;I want ...
2                                I want to be fit
3           I want to be fit;I want to lose weight
4                                I want to be fit

   daily_steps
0        12270
1         5860
2        10390
3        10191
4        10734
```

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

（以下三题各 1 分）

1、模型性能（答案在 report.txt 文件中）

均方误差（MSE）	8096170.758224316
平均绝对误差（MAE）	2421.827880665033
决定系数（R^2）	-0.1541458336017123

2、错误分析

1.特征选择问题：
当前选择的特征可能不足以解释目标变量 daily_steps 的变化。可能需要更多的相关特征或更详细的特征工程。
2.模型复杂度：
决策树模型可能过于简单或过拟合。可以考虑使用更复杂的模型，如随机森林或 XGBoost。
3.数据预处理：
分类变量的处理可能不够充分。使用 pd.get_dummies 进行独热编码是正确的，但可能需要进一步检查是否有缺失值或其他异常情况。
4.评估指标错误：
决定系数的计算是正确的，但结果表明模型性能不佳。

3、改进建议

1.特征工程：
探索更多的潜在特征，如时间序列特征(如星期几、月份)、历史步数数据等。使用特征重要性分析来选择最有影响力的特征。
2.模型选择：
尝试使用集成学习方法，如随机森林或 XGBoost，这些模型通常能提供更好的泛化能力。

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

1、 分析报告（选择素材中的功能调用类型填写）

用户使用习惯

最常被使用的功能:	调整音量	查询新闻	查天气

功能使用频率

最受欢迎的功能	调整音量	
较少使用的功能	播放音乐	控制家居

响应时间分析（响应时间适中的功能：提醒事项/调整音量/查询知识/设置闹钟/播放音乐/查天气，6 选 3）

响应时间较长的功能	控制家居		
响应时间适中的功能	提醒事项	调整音量	查询知识
响应时间较短的功能	查询新闻		

2、 优化方向及解决方案（仅需回答 3 个优化方向和对应解决方案）

- 1. 优化方向：网络连接与设备交互优化

解决方案：强化网络连接稳定性，采用更高效的通信协议，减少控制家居功能的响应时间。

- 2. 优化方向：提升信息检索效率

解决方案：优化查询知识的检索算法，加快数据处理速度，提升用户体验。

- 3. 优化方向：增强本地处理能力

解决方案：增加本地缓存和预加载机制，尤其在播放音乐和查天气上，以减少对外部资源的依赖。

- 4. 优化方向

改善闹钟与提醒功能；解决方案：设计更直观的闹钟和提醒事项设置流程，增加个性化选项，鼓励用户更频繁地使用这些功能。

- 5. 优化方向

用户界面与语音识别优化；解决方案：提升语音识别准确率，简化用户界面设计，确保用户能够快速、准确地调用所需功能。

Made by QuadAI

请勿修改答题卷，在指定单元格内填写答案

1、 分析报告

用户使用习惯

	平均光线亮度值	平均色温值
06:00 - 12:00	51.74468085	3689.51773
12:00 - 18:00	49.93055556	3732.402778
18:00 - 24:00	48.05586592	3661.351955

智能场景使用频率

频繁使用的场景	Relax Mode	
适中使用的场景	Work Mode	Reading Mode
较少使用的场景	Sleep Mode	

响应时间分析（延迟瓶颈：网络延迟/系统处理能力/硬件限制，3 选 2）

平均响应时间	1.063560499	
延迟瓶颈	网络延迟	系统处理能力

2、 优化方向及解决方案（仅需回答 3 个优化方向和对应解决方案）

- 1. 优化方向：提升响应速度；解决方案：硬件升级（增加处理器速度或使用更高效的 LED 驱动器来减少控制响应时间）、软件优化（改进算法，减少不必要的计算步骤，提高数据处理效率）、网络优化（确保网络连接稳定，减少数据传输延迟，必要时采用更可靠的网络协议）。
- 2. 优化方向：个性化场景定制；解决方案：根据用户使用习惯，自动调整预设场景参数，如亮度和色温等。
- 3. 优化方向：用户体验增强；解决方案：开发更直观的用户界面，简化场景切换操作。
- 4. 优化方向：功能拓展与集成；解决方案：集成更多传感器（如人体感应、环境光传感器），实现更加智能的自动化控制；与智能家居其他设备（如智能窗帘、空调等）联动，提供更全面的智能家居体验。

Made by OladAI

请勿修改答题卷，在指定单元格内填写答案

1、 分析报告

用户活动模式

	用户平均步数
06:00 - 08:00	5068.099048
17:00 - 20:00	5005.6475
其余时段（步数为 0 时段不计入）	1101.247792

健康指标关注度

最受关注的指标	步数	
较少关注的指标	心率	睡眠时长

数据同步性能（影响因素：网络状况不佳、设备电量低、手机后台运行程序过多、数据包大小等，多选 2）

平均延迟时间（秒）	0.697955845	
影响因素	网络状况不佳	设备电量低

2、 优化方向及解决方案（仅需回答 3 个优化方向和对应解决方案）

- 1. 优化方向：用户活动模式的优化；解决方案：早晨和傍晚是用户活跃的高峰期，手环可以在这些时段自动开启高灵敏度模式，以更准确地捕捉步数和其他运动数据；对于低活跃时段，手环可以降低传感器的灵敏度，以节省电量并减少不必要的数据记录。
- 2. 优化方向：健康指标关注度的优化；解决方案：增加对心率和睡眠时长监测功能的推广和教育，让用户了解这些指标的重要性；通过软件更新，优化心率和睡眠监测算法，提高数据的准确性和可靠性。
- 3. 优化方向：数据同步性能的优化；解决方案：优化数据包的大小和格式，减少传输所需的时间；在手环上实施有效的电源管理策略，确保在数据同步过程中有足够的电量；提供用户界面管理选项，让用户能够控制后台程序，减少对数据同步的干扰；增强网络模块，支持更稳定的数据传输，尤其是在网络状况不佳的情况下。
- 4. 优化方向：软件和硬件的升级；解决方案：根据用户反馈和使用数据，定期更新手环的固件和应用程序，以提高性能和用户体验；考虑使用更先进的传感器和处理器，以提高数据采集和处理的速度和准确性。
- 5. 优化方向：用户界面和体验的改进；解决方案：优化用户界面，使其更加直观易用，让用户能够轻松查看和分析他们的健康数据；提供个性化的设置选项，让用户可以根据自己的需求和喜好定制手环的功能。
- 6. 优化方向：教育和社区建设；解决方案：建立用户社区，鼓励用户分享他们的健康数据和经验，增加用户粘性；提供健康和健身相关的教育资源，帮助用户更好地理解他们的数据，并根据数据做出健康决策。

Made by DuadAI

请勿修改答题卷，在指定单元格内填写答案

1、 分析报告

用户活动周期

健康指标变化趋势：

1. 早上 7:30 分的平均血压值最高，之后时间平均血压值都在标准范围内。 2. 血糖处于正常水平；即空腹血糖处于正常水平，餐后血糖会上升，然后随着时间的推移而逐步降低。 3. 体脂连续一周维持在 0.17 的水平。

高风险时间段：

早上时间段（6: 00 - 10: 00）的血压。

安全时间段:

除去早上时间段（6: 00 - 10: 00）外的其余时间段的血压，全天的血糖。

健康指标偏好度

受用户青睐的功能	血压监测	血糖检测
较少使用的功能	体脂分析	

注:

收缩压值、舒张压值属于血压监测功能。

血糖值属于血糖检测功能。

体脂值属于体脂分析功能。

系统响应与准确性

响应时间较长的功能	体脂分析
响应时间适中的功能	血压监测
响应时间较短的功能	血糖检测

2、 优化方向及解决方案（仅需回答 3 个优化方向和对应解决方案）

- 1. 优化方向：优化血压监测算法；解决方案:开发一个智能算法，该算法能够识别血压模式并在血压可能升高的时间段自动调整监测频率。
- 2. 优化方向：改进血糖监测功能；解决方案:集成更精确的血糖传感器，并开发一个应用程序，该程序能够根据用户的血糖数据提供实时反馈和建议。
- 3. 优化方向：增强体脂分析功能；解决方案:优化体脂分析算法，减少响应时间（当前为 0.67 秒），并提供更详细的体脂报告。
- 4. 优化方向：提升系统响应速度；解决方案:升级硬件组件，如使用更快的处理器，优化数据处理算法，减少延迟。
- 5. 优化方向：增加用户参与度；解决方案:开发一个用户参与计划，通过应用程序提供健康目标设定、进度跟踪和奖励。
- 6. 优化方向：数据安全和隐私保护；解决方案:实施更强的数据加密技术，确保所有传输和存储的数据都符合最新的隐私保护标准。
- 7. 优化方向：集成人工智能；解决方案:开发基于机器学习的分析工具，这些工具能够从用户的健康数据中学习并提供个性化的健康建议。
- 8. 优化方向：提升用户界面和体验；解决方案:重新设计应用程序的用户界面，确保信息清晰、易于访问，并提供更好的用户体验。

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

1、 分析报告

用户环境偏好

	平均温度	平均湿度	平均光照
06:00 - 12:00	24.71818342	50.17551441	540.939268
13:00 - 18:00	24.92491993	49.08463089	557.7976734
19:00 - 05:00	25.02322393	49.91843944	542.748874

系统响应时间（影响因素：系统架构、网络连接、硬件性能、软件优化、数据量、用户界面、系统负载、外部干扰等，多选 2。）

平均响应时间	3.0193806438811	
影响因素	网络连接	硬件性能

能源消耗分析（节能潜力：智能调度、温控系统优化、设备智能控制、用户行为习惯、系统性能优化、能源消耗预警与提示等，多选 2。）

平均能源消耗	1.020874562	
节能潜力	智能调度	温控系统优化

说明：节能潜力：智能调度、温控系统优化、设备智能控制、用户行为习惯、系统性能优化、能源消耗预警与提示等选 2 即可。

2、 优化方向及解决方案（仅需回答 3 个优化方向和对应解决方案）

-1. 优化方向：智能调度与温控系统优化；解决方案：开发一个智能温控系统，该系统能够学习用户的习惯并预测他们的需求，自动调整室内环境以保持最佳舒适度和节能效果。

-2. 优化方向：设备智能控制；解决方案：集成智能传感器和控制系统，使设备能够根据环境变化和用户行为自动调节运行状态。

-3. 优化方向：用户行为习惯；解决方案：开发一个用户行为分析工具，该工具能够识别用户的能源使用习惯，并提供定制化的节能方案。

-4. 优化方向：系统性能优化；解决方案：改进系统架构和网络连接，减少数据处理和命令执行的延迟，确保快速响应用户的操作。

-5. 优化方向：能源消耗预警与提示；解决方案：实现一个能源管理平台，该平台能够实时监控能源消耗并提供反馈，帮助用户做出节能决策。

-6. 优化方向：增强用户界面；解决方案：设计一个友好的用户界面，集成语音控制和触摸屏操作，提供清晰的环境状态显示和控制选项。

-7. 优化方向：集成可再生能源；解决方案：与能源公司合作，为用户提供太阳能解决方案，优化能源结构。

-8. 优化方向：智能家电系统的能耗分析；解决方案：开发能耗分析工具，帮助用户了解家电的能源效率，并提供节能建议。

Made by QuaAIT

In [1]:

3.2.1

```python
import onnxruntime as ort
import numpy as np
import scipy.special
from PIL import Image


# 预处理图像
def preprocess_image(image, resize_size=256, crop_size=224, mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]):
  image = image.resize((resize_size, resize_size), Image.BILINEAR)
  w, h = image.size
  left = (w - crop_size) / 2
  top = (h - crop_size) / 2
  image = image.crop((left, top, left + crop_size, top + crop_size))
  image = np.array(image).astype(np.float32)
  image = image / 255.0
  image = (image - mean) / std
  image = np.transpose(image, (2, 0, 1))
  image = image.reshape((1,) + image.shape)
  return image


# 模型加载 2分
session = ort.InferenceSession('resnet.onnx')


# 加载类别标签
labels_path = 'labels.txt'
with open(labels_path) as f:
  labels = [line.strip() for line in f.readlines()]


# 获取模型输入和输出的名称
input_name = session.get_inputs()[0].name
output_name = session.get_outputs()[0].name


# 加载图片 2分
image = Image.open('img_test.jpg').convert('RGB')


# 预处理图片 2分
processed_image = preprocess_image(image)


# 确保输入数据是 float32 类型
processed_image = processed_image.astype(np.float32)


# 进行图片识别 2分
output = session.run([output_name], {input_name: processed_image})[0]


# 应用 softmax 函数获取概率 2分
probabilities = scipy.special.softmax(output, axis=-1)


# 获取最高的5个概率和对应的类别索引 3分
top5_idx = np.argsort(probabilities[0])[-5:][::-1]
top5_prob = probabilities[0][top5_idx]


# 打印结果
print("Top 5 predicted classes:")
for i in range(5):
  print(f"{i+1}: {labels[top5_idx[i]]} - Probability: {top5_prob[i]}")
```

```
Top 5 predicted classes:
1: tusker - Probability: 0.9328869581222534
2: Indian elephant - Probability: 0.06619396805763245
3: African elephant - Probability: 0.0009152606944553554
4: gorilla - Probability: 4.810995619664027e-07
5: water buffalo - Probability: 3.850165910534997e-07
```

3.2.1-1.jpg

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

人机交互的最优方式（答对 3 条以上正确得 1 分）

1. 用户界面设计：提供一个简洁直观的用户界面，方便用户上传图片和查看识别结果。
2. 模型加载：系统启动时预加载模型和标签，减少用户等待时间。
3. 图像上传与预处理：允许用户上传图片，并自动进行必要的预处理。
4. 图像识别：后台使用"resnet.onnx”模型处理预处理后的图片。
5. 结果展示：清晰展示识别结果，包括最可能的类别和概率。
6. 交互反馈：提供用户反馈选项，以改进模型性能。
7. 帮助与支持：内置帮助文档和客服支持，提升用户体验。
8. 性能优化：优化系统响应速度和模型处理能力。
9. 安全性考虑：确保用户数据安全和隐私保护。
10. 多语言支持：界面支持多语言，满足全球用户需求。
11. 可访问性：确保 UI 无障碍，方使所有用户操作。

Made by QuadAIT

3.2.2

In [3]:
```python
import onnxruntime
import numpy as np
from PIL import Image


# 加载ONNX模型  2分
ort_session = onnxruntime.InferenceSession('mnist.onnx')


# 加载图像 2分
image = Image.open('img_test.png').convert('L')  # 转为灰度图


#图像预处理
image = image.resize((28, 28))  # 调整大小为MNIST模型的输入尺寸2分
image_array = np.asarray(image, dtype=np.float32)  # 转为numpy数组2分
image_array = np.expand_dims(image_array, axis=0)  # 添加batch维度2分
image_array = np.expand_dims(image_array, axis=0)  # 添加通道维度2分


#返回模型输入列表 2分
ort_inputs = {ort_session.get_inputs()[0].name: image_array}
# 执行预测 2分
ort_outs = ort_session.run(None, ort_inputs)


# 获取预测结果 2分
predicted_class = np.argmax(ort_outs[0])


# 输出预测结果
print(f"Predicted class: {predicted_class}")
```

```
Predicted class: 8
```

3.2.2-1.jpg

In [ ]:

Made by QuadAI

请勿修改答题卷，在指定单元格内填写答案

人机交互的最优方式（答对 3 条以上正确得 1 分）

1. 界面设计:设计一个简洁的用户界面，包含一个上传按钮和一个显示识别结果的区域。
2. 模型加载:启动系统时自动加载"mnist.onnx"模型，无需用户干预。
3. 图像上传:用户通过界面上传手写数字图片"img_test.png”。
4. 预处理:系统自动对上传的图片进行预处理，如调整大小、灰度化、标准化等。
5. 识别执行:处理完成后，系统自动使用“mnist.onnx”模型进行数字识别。
6. 结果显示:在界面上清晰展示识别出的数字，并提供语音反馈作为辅助。
7. 反馈机制:允许用户提供反馈，如“正确“或”错误”，以优化模型性能。
8. 性能优化:确保系统响应迅速，提供即时的识别结果。
9. 安全性:确保用户上传的图片数据安全，不被未授权访问。
10. 多语言界面:提供多语言支持，以适应不同用户的需求。

Made by QuadAIT

In [4]:

3.2.3

```python
# 导入必要的库
import numpy as np
from PIL import Image
import onnxruntime as ort


# 定义预处理函数，用于将图片转换为模型所需的输入格式
def preprocess(image_path):
    input_shape = (1, 1, 64, 64)    # 模型输入期望的形状，这里是 (N, C, H, W)，N=batch size, C=channels, H=height, W=width
    img = Image.open(image_path).convert('L')    # 打开图像文件并将其转换为灰度图  1分
    img = img.resize((64, 64), Image.ANTIALIAS)             # 调整图像大小到模型输入所需的尺寸
    img = img.resize((64, 64), Image.LANCZOS)    # 调整图像大小到模型输入所需的尺寸,(因为PIL版本问题，在 Pillow 9.1.0 及以上版本，Image.ANTIALIAS 被弃用，自行修改代码Image.LANCZOS)
    img_data = np.array(img, dtype=np.float32)    # 将PIL图像对象转换为numpy数组，并确保数据类型是float32
    # 调整数组的形状以匹配模型输入的形状
    img_data = np.expand_dims(img_data, axis=0)  # 添加 batch 维度
    img_data = np.expand_dims(img_data, axis=1)  # 添加 channel 维度
    assert img_data.shape == input_shape, f"Expected shape {input_shape}, but got {img_data.shape}"    # 确保最终的形状与模型输入要求的形状一致
    return img_data    # 返回预处理后的图像数据


# 定义情感类别与数字标签的映射表 3分
emotion_table = {'neutral':0, 'happiness':1, 'surprise':2,'sadness':3,
                 'anger':4, 'disgust':5, 'fear':6, 'contempt':7}


# 加载模型 3分
ort_session = ort.InferenceSession('emotion-ferplus.onnx')    # 使用onnxruntime创建一个会话，用于加载并运行模型


# 加载本地图片并进行预处理 3分
input_data = preprocess('img_test.png')


# 准备输入数据，确保其符合模型输入的要求
ort_inputs = {ort_session.get_inputs()[0].name: input_data}    # ort_session.get_inputs()[0].name 是获取模型的第一个输入的名字


# 运行模型，进行预测 3分
ort_outs = ort_session.run(None, ort_inputs)


# 解码模型输出，找到预测概率最高的情感类别 3分
predicted_label = np.argmax(ort_outs[0])


# 根据预测的标签找到对应的情感名称 3分
predicted_emotion = list(emotion_table.keys())[predicted_label]


# 输出预测的情感
print(f"Predicted emotion: {predicted_emotion}")
```

```
Predicted emotion: surprise
```

3.2.3-1.jpg

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

人机交互的最优方式（答对 3 条以上正确得 1 分）

1. 界面设计:创建一个直观的用户界面，包括一个图像上传区域和一个结果展示区域。
2. 模型和标签加载:系统启动时预加载"emotion-ferplus.onnx"模型和情感类别映射表。
3. 图像上传:用户通过界面上传面部图像"img_test.png”。
4. 图像预处理:系统自动对上传的图像进行必要的预处理，如裁剪、缩放、归一化等。
5. 表情识别:预处理完成后，系统自动使用模型进行面部表情识别。
6. 结果展示:在界面上展示识别结果，包括表情类别和相应的数字标签。
7. 反馈收集:提供用户反馈选项，以便用户确认识别的准确性。
8. 结果应用:根据识别结果，系统可以提供进一步的交互或服务，如情感分析报告。
9. 性能优化:确保系统响应迅速，减少用户等待时间。
10. 隐私保护:确保用户上传的图像数据安全，遵守隐私保护法规。

Made by QuadAIT

In [1]:

3.2.4

```python
import onnxruntime as ort
import numpy as np
import scipy.special
from PIL import Image


# 预处理图像
def preprocess_image(image, resize_size=256, crop_size=224, mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]):
    image = image.resize((resize_size, resize_size), Image.BILINEAR)
    w, h = image.size
    left = (w - crop_size) / 2
    top = (h - crop_size) / 2
    image = image.crop((left, top, left + crop_size, top + crop_size))
    image = np.array(image).astype(np.float32)
    image = image / 255.0
    image = (image - mean) / std
    image = np.transpose(image, (2, 0, 1))
    image = image.reshape((1,) + image.shape)
    return image


# 加载模型  2分
session = ort.InferenceSession('flower-detection.onnx')


# 加载类别标签 2分
with open('labels.txt') as f:
    labels = [line.strip() for line in f.readlines()]


# 获取模型输入和输出的名称
input_name = session.get_inputs()[0].name
output_name = session.get_outputs()[0].name


# 加载图片  2分
image = Image.open('flower_test.png').convert('RGB')


# 预处理图片  2分
processed_image = preprocess_image(image)


# 确保输入数据是 float32 类型
processed_image = processed_image.astype(np.float32)


# 进行图片识别  2分
output = session.run([output_name], {input_name: processed_image})[0]


# 应用 softmax 函数获取识别分类后的准确率  2分
accuracy = scipy.special.softmax(output, axis=-1)


# 获取预测的类别索引
predicted_idx =  np.argmax(accuracy)


# 获取预测的准确值（转换为百分比）
prob_percentage =  accuracy[0,predicted_idx]*100


# 获取预测的类别标签
predicted_label = labels[predicted_idx]


# 输出预测结果，包含百分比形式的概率
print(f"Predicted class: {predicted_label}, Accuracy: {prob_percentage:.2f}%")
```

```
Predicted class: daisy, Accuracy: 96.41%
```

3.2.4-1.jpg

In [ ]:

Made by QuadAIT

请勿修改答题卷，在指定单元格内填写答案

人机交互的最优方式（答对 3 条以上正确得 1 分）

1. 界面设计:设计一个用户友好的界面，包括一个明显的图片上传按钮和一个结果展示区域。
2. 模型和标签加载:在系统启动时预加载"flower-detection.onnx"模型和“labels.txt”类别标签。
3. 图像上传:用户通过界面上传花朵图片"flower_test.png”。
4. 图像预处理:系统自动对上传的图片进行预处理，如调整大小、裁剪、归一化等，以适应模型输入要求。
5. 花朵识别:系统使用“flower-detection.onnx”模型对预处理后的图片进行花朵识别。
6. 结果展示:在界面上清晰展示识别结果，包括花朵的预测类型和识别的准确率。
7. 反馈机制:允许用户提供反馈，如“正确“或“错误”，以持续改进模型性能。
8. 教育性互动:对于识别结果，提供关于花朵的额外信息，如花名、生长习性等，增加用户参与度。
9. 性能优化:确保系统响应迅速，提供即时的识别反馈。
10. 隐私保护:确保用户上传的图像数据安全，不被未授权访问或存储。
11. 多语言支持:提供多语言界面，以适应不同地区用户的需求。
12. 可访问性设计:确保 UI 符合可访问性标准，使所有用户包括残障人士都能使用。

Made by qcdAIT

In [5]:

3.2.5

```python
import os
import time
import cv2
import numpy as np
import vision.utils.box_utils_numpy as box_utils
import onnxruntime as ort

# 定义预测函数，对模型输出的边界框和置信度进行后处理
def predict(width, height, confidences, boxes, prob_threshold, iou_threshold=0.3, top_k=-1):
    boxes = boxes[0]
    confidences = confidences[0]
    picked_box_probs = []
    picked_labels = []
    for class_index in range(1, confidences.shape[1]):
        probs = confidences[:, class_index]
        mask = probs > prob_threshold
        probs = probs[mask]
        if probs.shape[0] == 0:
            continue
        subset_boxes = boxes[mask, :]
        box_probs = np.concatenate([subset_boxes, probs.reshape(-1, 1)], axis=1)
        box_probs = box_utils.hard_nms(box_probs,
                                       iou_threshold=iou_threshold,
                                       top_k=top_k,
                                       )
        picked_box_probs.append(box_probs)
        picked_labels.extend([class_index] * box_probs.shape[0])
    if not picked_box_probs:
        return np.array([]), np.array([]), np.array([])
    picked_box_probs = np.concatenate(picked_box_probs)
    picked_box_probs[:, 0] *= width
    picked_box_probs[:, 1] *= height
    picked_box_probs[:, 2] *= width
    picked_box_probs[:, 3] *= height
    return picked_box_probs[:, :4].astype(np.int32), np.array(picked_labels), picked_box_probs[:, 4]

# 从标签文件中读取每一行，并去除行首尾的空白字符，得到类别名称列表 2分
class_names = [name.strip() for name in open('voc-model-labels.txt').readlines()]

# 创建 ONNX Runtime 的推理会话，用于运行模型进行推理 2分
ort_session = ort.InferenceSession('version-RFB-320.onnx')

# 获取模型输入的名称 2分
input_name = ort_session.get_inputs()[0].name

# 定义保存检测结果图像的目录路径
result_path = "./detect_imgs_results_onnx"

# 定义置信度阈值，用于筛选出置信度较高的检测结果
threshold = 0.7
# 定义存储待检测图像的目录路径
path = "imgs"
# 用于统计所有图像中检测到的目标框总数，初始化为 0
sum = 0

# 如果保存结果的目录不存在，则创建该目录 2分
if not os.path.exists(result_path):
    os.makedirs(result_path)

# 获取指定目录下的所有文件和文件夹名称列表
listdir = os.listdir(path)

# 遍历目录下的每个文件
for file_path in listdir:
    # 拼接图像文件的完整路径
    img_path = os.path.join(path, file_path)
    # 使用 OpenCV 读取图像文件 2分
    orig_image = cv2.imread(img_path)
    # 将图像从 BGR 颜色空间转换为 RGB 颜色空间（许多模型要求输入为 RGB 格式）
    image = cv2.cvtColor(orig_image, cv2.COLOR_BGR2RGB)
    # 将图像调整为 320x240 的尺寸（符合模型输入的尺寸要求） 2分
    image = cv2.resize(image, (320, 240))
    # 定义图像归一化的均值数组 2分
    image_mean = np.array([127, 127, 127])
    # 对图像进行归一化处理，减去均值并除以 128
    image = (image - image_mean) / 128
```

Made by QuadAIT

```
    # 将图像的维度从 (高度, 宽度, 通道数) 转换为 (通道数, 高度, 宽度)
    image = np.transpose(image, [2, 0, 1])
    # 在第一个维度上扩展一个维度，将图像变为 (1, 通道数, 高度, 宽度)，以符合模型输入的维度要求  1分
    image = np.expand_dims(image, axis=0)
    # 将图像数据类型转换为 float32 类型
    image = image.astype(np.float32)
    # 记录开始时间，用于计算模型推理的耗时
    time_time = time.time()
    # 使用 ONNX Runtime 运行模型，输入图像数据，得到模型输出的置信度和边界框  2分
    confidences, boxes = ort_session.run(None, {input_name: image})
    # 计算并打印模型推理的耗时
    print("cost time:{}".format(time.time() - time_time))
    # 调用 predict 函数对模型输出的边界框和置信度进行后处理，得到最终的边界框、类别标签和置信度
    boxes, labels, probs = predict(orig_image.shape[1], orig_image.shape[0], confidences, boxes, threshold)
    # 遍历每个检测到的目标框
    for i in range(boxes.shape[0]):
        # 获取当前目标框的坐标
        box = boxes[i, :]
        # 生成当前目标框的标签字符串，包含类别名称和置信度
        label = f"{class_names[labels[i]]}: {probs[i]:.2f}"

        # 在原始图像上绘制目标框，颜色为 (255, 255, 0)，线条粗细为 4
        cv2.rectangle(orig_image, (box[0], box[1]), (box[2], box[3]), (255, 255, 0), 4)
        # 将绘制了目标框的图像保存到结果目录中
        cv2.imwrite(os.path.join(result_path, file_path), orig_image)
    # 累加当前图像中检测到的目标框数量到总数中
    sum += boxes.shape[0]
# 打印所有图像中检测到的目标框总数
print("sum:{}".format(sum))
```

```
cost time:0.016932249069213867
sum:4
```

3.2.5-1.jpg

In [ ]:

Made by QuadAIT

3.2.5.docx

请勿修改答题卷，在指定单元格内填写答案

人机交互的最优方式（答对 3 条以上正确得 1 分）

1. 用户界面设计：提供一个简洁直观的用户界面，方便用户上传图片和查看识别结果。 2. 模型加载：系统启动时预加载模型和标签，减少用户等待时间。 3. 图片上传与预处理：允许用户上传图片，并自动进行必要的预处理。 4. 图片识别：后台使用 onnx 模型处理预处理后的图片。 5. 结果展示：清晰展示识别结果，包括最可能的类别和概率。 6. 交互反馈：提供用户反馈选项，以改进模型性能。 7. 帮助与支持：内置帮助文档和客服支持，提升用户体验。 8. 性能优化：优化系统响应速度和模型处理能力。 9. 安全性考虑：确保用户数据安全和隐私保护。 10. 多语言支持：界面支持多语言，满足全球用户需求。 11. 可访问性：确保 UI 无障碍，方便所有用户操作。

在“detect_imgs_results_onnx”文件夹中

1.jpg

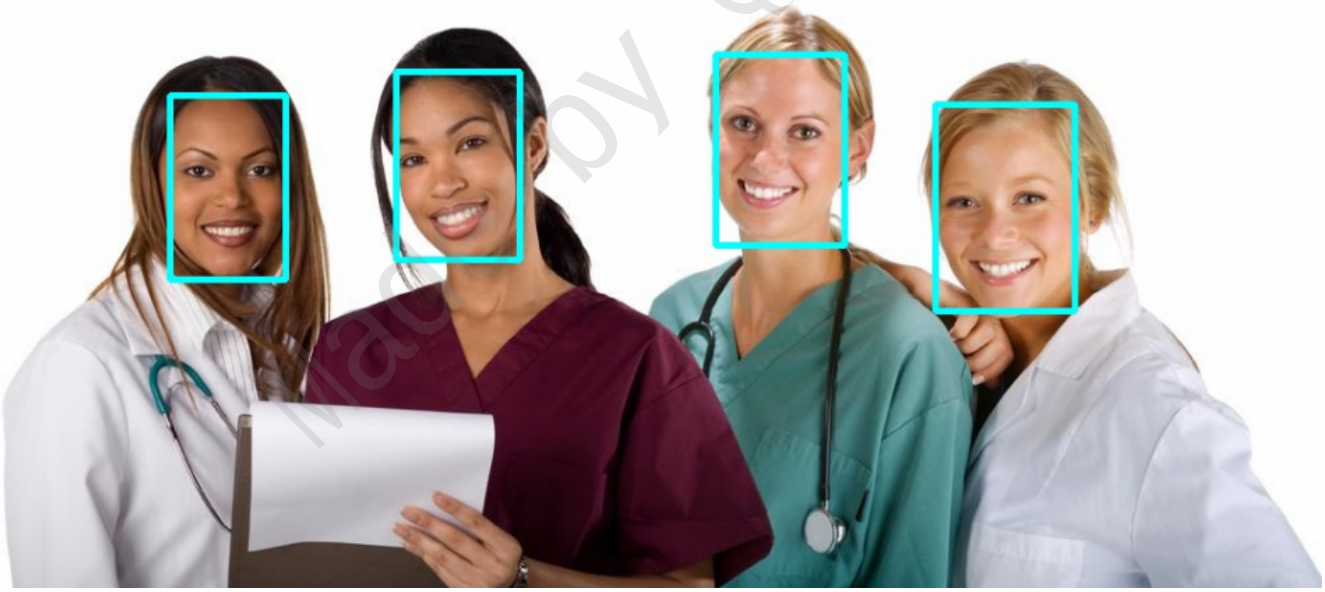

Machine by QuadAIT

在下划线上填写答案。

根据学习大纲补充学习目标

引言

学习目标：了解数据标注的重要性和应用场景。

内容：

介绍人工智能在康复训练中的应用，数据标注在个性化康复训练计划中的作用。

数据标注基础理论

学习目标：掌握数据标注的基本概念和类型。

内容：

什么是数据标注？

数据标注的类型：文本、图像、视频、音频。

数据标注在人工智能中的作用和重要性。

Label Studio 简介与安装

学习目标：了解 Label Studio 工具的基本功能和安装方法。

内容：

Label Studio 简介及应用场景。

安装与配置 Label Studio。

Label Studio 界面介绍和基本操作。

文本数据标注

学习目标：掌握文本数据标注的方法和技巧。

内容：

文本标注类型：命名实体识别、情感分析等。

Label Studio 文本标注功能演示。

实践操作：标注一个文本数据集。

图像数据标注

学习目标：掌握图像数据标注的方法和技巧。

内容：

图像标注类型：图像分类、目标检测、图像分割等。

Label Studio 图像标注功能演示。

实践操作：标注一个图像数据集。

视频数据标注

学习目标：掌握视频数据标注的方法和技巧。

内容：

视频标注类型：动作识别、事件检测等。

Label Studio 视频标注功能演示。

实践操作：标注一个视频数据集。

音频数据标注

学习目标：掌握音频数据标注的方法和技巧。

内容：

音频标注类型：语音识别、情感分析等。

Label Studio 音频标注功能演示。

实践操作：标注一个音频数据集。

综合项目实践

学习目标：综合运用所学知识进行数据标注项目。

Made by QuadAIT

内容：
项目介绍：为康复训练项目进行多模态数据标注（包括文本、图像、视频、音频）。
数据标注：学员分组进行实际数据标注任务。
项目评审：展示标注成果，讲解标注思路和遇到的问题。

总结与答疑

学习目标：巩固所学内容，解决学员疑问。
内容：培训内容总结，关键点回顾，学员提问与解答。

评估测试

学习目标：评估学员掌握的数据标注技能。
内容：
理论测试：关于数据标注基本概念和 Label Studio 使用的笔试。
实操测试：要求学员完成指定的数据标注任务。

Made by QuadAIT

在下划线上填写答案。

根据学习大纲补充学习目标

引言

学习目标：了解网页爬虫的重要性和应用场景。

内容：

介绍人工智能在金融数据采集中的应用，网页爬虫在获取上市公司财务报告中的作用。

网页爬虫基础理论

学习目标：掌握网页爬虫的基本概念和工作原理。

内容：

什么是网页爬虫？

网页爬虫的工作流程和基本结构。

机器人协议（robots.txt）的作用和遵守方法。

常用网页爬虫工具简介

学习目标：了解常用网页爬虫工具的功能和特点。

内容：

BeautifulSoup：用于解析 HTML 和 XML 文档。

Scrapy：一个快速、高效的网页爬虫框架。

Selenium：用于模拟浏览器操作，处理动态网页。

环境搭建与工具安装

学习目标：掌握网页爬虫工具的安装和环境配置。

内容：

安装 Python 和 pip 包管理工具。

安装并配置 BeautifulSoup、Scrapy、Selenium。

网页数据解析

学习目标：掌握网页数据解析的方法和技巧。

内容：

使用 BeautifulSoup 进行 HTML 解析。

使用 XPath 和 CSS 选择器提取数据。

实践操作：解析一个简单的网页数据。

动态网页处理

学习目标：掌握处理动态网页的方法。

内容：

使用 Selenium 模拟浏览器操作。

处理动态加载的数据，如 Ajax 请求。

实践操作：爬取一个动态加载的网页数据。

Scrapy 框架实战

学习目标：掌握使用 Scrapy 框架进行大规模数据采集。

内容：

Scrapy 项目的创建和基本配置。

编写爬虫脚本，设置抓取规则。

数据存储与导出：将数据保存为 CSV、JSON 等格式。

实践操作：构建一个 Scrapy 爬虫项目，获取上市公司财务报告。

数据清洗与处理

学习目标：掌握爬取数据的清洗和处理方法。

内容：

Made by QuadAIT

数据去重、缺失值处理。

数据格式转换与规范化。

实践操作：对获取的财务报告数据进行清洗和处理。

综合项目实践

学习目标：综合运用所学知识进行网页爬虫项目。

内容：

项目介绍：构建一个完整的财务报告爬虫项目。

数据采集：获取多个网站的财务报告数据。

数据处理与分析：清洗并分析获取的数据。

项目评审：展示爬虫成果，讲解实现思路和遇到的问题。

总结与答疑

学习目标：巩固所学内容，解决学员疑问。

内容：培训内容总结，关键点回顾，学员提问与解答。

评估测试

学习目标：评估学员掌握的网页爬虫技能。

内容：

理论测试：关于网页爬虫基本概念和工具使用的笔试。

实操测试：要求学员完成指定的网页爬虫任务。

Made by QuadAIT

在下划线上填写答案。

根据学习大纲补充学习目标

引言

学习目标：__了解数据清洗的重要性和应用场景。__

内容：

介绍人工智能在康复训练中的应用，数据清洗在处理康复数据中的作用。

数据清洗基础理论

学习目标：__掌握数据清洗的基本概念和流程。__

内容：

什么是数据清洗？

数据清洗的常见任务：数据去重、缺失值处理、数据格式转换等。

数据清洗在数据分析和模型训练中的重要性。

常用数据清洗工具简介

学习目标：__了解常用数据清洗工具的功能和特点。__

内容：

Pandas：强大的数据处理与分析工具。

NumPy：高性能科学计算和数据处理库。

OpenRefine：用于数据清洗的开源工具。

Dask：用于处理大规模数据的并行计算库。

环境搭建与工具安装

学习目标：__掌握数据清洗工具的安装和环境配置。__

内容：

安装 Python 和 pip 包管理工具。

安装并配置 Pandas、NumPy、OpenRefine、Dask。

Pandas 实战

学习目标：__掌握 Pandas 在数据清洗中的应用。__

内容：

数据导入与导出：读取和保存 CSV、Excel 等格式的数据。

数据筛选与过滤：条件筛选、去重、缺失值处理。

数据转换：数据类型转换、时间序列处理。

实践操作：使用 Pandas 清洗一个康复数据集。

NumPy 实战

学习目标：综合运用所学知识进行数据清洗项目。

内容：

项目介绍：清洗一个多来源、多格式的康复数据集。

数据采集：导入多种格式的数据。

数据清洗：使用 Pandas、NumPy、OpenRefine、Dask 进行清洗。

项目评审：展示清洗成果，讲解实现思路和遇到的问题。

Made by QuadAIT

在下划线上填写答案。

根据学习大纲补充学习目标

数据清洗基础理论

学习目标：掌握数据清洗的基本概念和流程。

内容：

什么是数据清洗？

数据清洗的常见任务：数据去重、缺失值处理、数据格式转换等。

数据清洗在数据分析和模型训练中的重要性。

Pandas 简介与安装

学习目标：掌握使用 Pandas 进行数据导入与导出的方法。

内容：

读取 CSV、Excel、SQL 等格式的数据。

保存数据到 CSV、Excel 等格式。

实践操作：导入和导出康复数据集。

数据筛选与过滤

学习目标：掌握使用 Pandas 进行数据筛选与过滤的方法。

内容：

条件筛选：基于单列或多列的条件筛选数据。

数据去重：去除重复记录。

缺失值处理：识别、删除和填充缺失值。

实践操作：筛选和过滤康复数据。

数据转换

学习目标：掌握使用 Pandas 进行数据转换的方法。

内容：

数据类型转换：转换数据类型（如字符串到日期）。

时间序列处理：处理和分析时间序列数据。

数据分列和合并：分割和合并数据列。

实践操作：转换和处理康复数据。

数据合并与重塑

学习目标：掌握使用 Pandas 进行数据合并与重塑的方法。

内容：

数据合并：concat 和 merge 方法。

数据重塑：pivot 和 melt 方法。

实践操作：合并和重塑康复数据。

数据分组与聚合

学习目标：掌握使用 Pandas 进行数据分组与聚合的方法。

内容：

数据分组：groupby 方法。

聚合函数：sum、mean、count 等。

实践操作：分组和

聚合康复数据。

数据可视化

学习目标：综合运用所学知识进行数据清洗项目。

内容：

项目介绍：清洗一个多来源的康复数据集。

数据采集：导入多种格式的数据。

数据清洗：使用 Pandas 进行数据清洗和转换。

项目评审：展示清洗成果，讲解实现思路和遇到的问题。

Made by QuadAIT

在下划线上填写答案。

根据学习大纲补充学习目标

数据可视化基础理论

学习目标：掌握数据可视化的基本概念和原则。

内容：

什么是数据可视化？

数据可视化的目的和优势。

常见的数据可视化类型：条形图、折线图、散点图、饼图等。

Matplotlib 简介与安装

学习目标：了解 Matplotlib 库的基本功能和安装方法。

内容：

Matplotlib 简介及其应用场景。

安装与配置 Matplotlib 库。

Matplotlib 基本构架与常用组件。

Matplotlib 基本绘图

学习目标：掌握 Matplotlib 基本绘图方法。

内容：

创建简单图表：折线图、条形图、饼图。

图表定制：标题、轴标签、图例、颜色等。

实践操作：使用 Matplotlib 绘制康复数据的基本图表。

Plotly 简介与安装

学习目标：了解 Plotly 库的基本功能和安装方法。

内容：

Plotly 简介及其应用场景。

安装与配置 Plotly 库。

Plotly 与 Jupyter Notebook 的结合使用。

Plotly 交互式绘图

学习目标：掌握 Plotly 交互式绘图方法。

内容：

创建交互式图表：折线图、散点图、饼图、地理图表。

图表交互功能：缩放、平移、悬停显示。

实践操作：使用 Plotly 绘制交互式康复数据图表。

数据可视化项目实战

学习目标：综合运用所学知识进行数据可视化项目。

内容：

项目介绍：对康复数据进行可视化分析。

数据采集与预处理：导入并清洗康复数据。

数据可视化：使用 Matplotlib、Seaborn、Plotly 进行可视化分析。

项目评审：展示可视化成果，讲解实现思路和遇到的问题。

总结与答疑

学习目标：巩固所学内容，解决学员疑问。

内容：培训内容总结，关键点回顾，学员提问与解答。

评估测试

学习目标：评估学员掌握的数据可视化技能。

内容：

理论测试：关于数据可视化基本概念和工具使用的笔试。

实操测试：要求学员完成指定的数据可视化任务。

made by QiadAIT

在下划线上填写答案，请勿修改其他内容。

智能零售分析系统数据采集和处理指导方案

1. 数据源确定

- 销售点（POS）数据：从收银系统获取交易记录，包括商品种类、数量、价格和购买时间。
- 顾客信息：会员卡使用数据，包括 会员基本信息、消费记录和积分兑换 。
- 库存管理系统：实时库存量、入库和出库记录。
- 顾客反馈：在线评价、投诉和建议。
- 外部数据：天气预报、节假日信息、竞争对手价格数据。

2. 数据采集方法

- API 接口：与内部系统（如 POS、CRM）和外部数据提供商建立 API 连接，自动化数据抓取。
- 传感器和物联网设备：在货架上安装 RFID 标签和重量传感器，监测商品存量。
- 社交媒体监听：通过社交媒体 API 监听品牌相关的公众讨论和评价。
- 顾客调查：定期发送电子问卷，收集顾客反馈。

3. 数据预处理

- 清洗： 去除重复、错误或无关的数据项 。
- 标准化： 统一数据格式，例如日期和时间的表示方式 。
- 整合：将来自不同来源的数据合并到单一数据库中，创建关联字段。

4. 数据安全与合规

- 加密传输：确保数据在传输过程中的安全。
- 访问控制：限制对敏感数据的访问权限，只允许授权人员查看。
- 匿名化处理：对个人信息进行去标识化，遵守 GDPR 等数据保护法规。

5. 数据存储与管理

- 云存储：选择可靠的云服务商，如 AWS 或 Azure，存储海量数据。
- 备份与恢复：定期备份数据，并测试恢复流程，以防数据丢失。

6. 数据分析与应用

- 建模： 使用机器学习算法预测销售趋势、顾客偏好和库存需求 。
- 可视化：开发仪表板展示关键指标，帮助管理层做出决策。
- 报告：定期生成销售、库存和顾客满意度报告，提供业务洞察。
- 通过上述方案，智能零售分析系统能够有效地采集、处理和分析大量数据，为企业提供决策支持，最终达到 提升业务效率和顾客满意度 的目标。

Made by QuadAIT

在下划线上填写答案，请勿修改其他内容。

AI 辅助的医疗影像诊断系统数据采集和处理指导方案

1. 数据采集方案

- 医学影像获取：确保影像质量，使用高分辨率的医疗设备获取清晰的影像资料，涵盖多种疾病类型和人群。
- 患者信息收集：在符合 HIPAA 等隐私保护法规的前提下，收集患者的病史、年龄、性别等基本信息，以及相关的实验室检查结果。
- ___专家标注数据___：邀请经验丰富的医生对影像进行标注，标记病灶位置、类型、大小等关键信息，作为训练 AI 模型的标注数据集。
- 数据脱敏处理：对收集的患者信息进行脱敏处理，确保患者隐私安全。

2. 数据处理方案

- 数据清洗与预处理：__剔除低质量影像，如模糊不清或曝光不当的图片，进行图像增强，如亮度调整、锐化处理，以提高图像质量__。
- 模型训练与验证：__使用深度学习框架，如 Tensorflow 或 PyTorch，构建卷积神经网络（CNN）模型，利用标注数据集进行训练，通过交叉验证确保模型的泛化能力__。
- 模型测试与优化：__在独立的测试数据集上评估模型性能，如准确率、召回率、F1 分数等，根据结果调整模型参数，直至达到满意的诊断准确率__。
- 系统集成与部署：将训练好的模型集成到医疗影像诊断系统中，部署在医院的服务器上，确保医生可以随时调用 AI 分析结果。

3. 数据安全与隐私保护

- 所有数据传输和存储过程都需加密，防止数据泄露。
- 遵守 HIPAA 等隐私法规，确保患者信息不被非法访问或滥用。
- 使用数据脱敏技术，如差分隐私，保护患者身份不被识别。

4. 系统优化与升级

- 定期收集医生和患者的反馈，评估系统性能，根据实际需求调整 AI 模型。
- 不断更新训练数据集，加入新的疾病类型或变异特征，提高__模型的诊断范围和准确性__。
- 跟踪 AI 技术的最新进展，适时引入更先进的算法，提升系统性能。

Made by QuadAI

在下划线上填写答案，请勿修改其他内容。

AI 智能安防监控系统采集和处理指导方案

1. 数据采集方法

- 高清视频流采集：部署高清摄像头，确保视频画面清晰，便于 AI 算法识别细节。
- 多角度覆盖：合理布置摄像头，确保__关键区域__无死角，覆盖所有入口、出口和敏感区域。
- 夜间与低光环境适应：使用带有红外夜视功能的摄像头，保证夜间或低光条件下仍能捕捉到清晰图像。
- 数据传输与存储：采用稳定的数据传输网络，确保视频流的实时传输，同时建立安全的__数据存储系统__，保存原始视频和分析结果。

2. 数据处理方案

- 视频流预处理：___对视频流进行实时压缩和格式转换，减少带宽消耗，同时进行初步的图像增强，如亮度调整、色彩校正__。
- 行为分析与异常检测：__利用深度学习模型，进行目标检测和行为识别，标记出异常行为__。
- 隐私保护算法：在不影响异常行为识别的前提下，对视频中无关个体进行模糊处理，保护个人隐私。
- 数据融合与决策支持：结合多个摄像头的数据，进行空间和时间上的数据融合，构建更全面的场景理解，为安全决策提供依据。

3. 系统优化与安全措施

- 算法优化：持续训练和优化 AI 模型，提升__识别精度和响应速度__。
- 隐私合规：确保系统设计和运营遵守 GDPR、CCPA 等数据保护法规，定期进行隐私影响评估。
- 安全防护：实施数据加密、访问控制和防火墙等安全措施，防止数据泄露和系统被攻击。

Made by QuadAI T

在下划线上填写答案，请勿修改其他内容。

自动驾驶汽车感知系统数据采集与标注指导方案

1. 数据采集方案

- 多传感器融合：__使用摄像头、雷达、激光雷达等多模态传感器，确保数据的全面性和准确性__。
- 场景覆盖：__在不同的天气条件、时间段、道路类型下采集数据，以增强模型的鲁棒性和泛化能力__。
- 事件触发采集：在特定事件发生时（如紧急刹车、避让行动），自动触发额外数据采集，以捕获关键时刻。
- 数据质量控制：__实施数据清洗流程，移除重复、低质量或不符合标准的样本，确保数据集的质量__。
- 数据加密与传输：采用安全的数据传输协议，确保数据在传输过程中的安全性。

2. 数据标注方案

- 定义标注标准：明确标注类别、边界框精度要求、遮挡处理规则等。
- 选择标注工具：使用专业的数据标注软件，支持 2D 框、3D 框、语义分割等标注类型。
- __培训标注团队__：对标注员进行专业培训，确保他们理解标注标准，熟悉工具使用。
- 执行标注任务：分配数据给标注团队，设定清晰的任务指标和截止日期。
- 质量控制与复查：实施多级检查，包括自动检查和人工复查，确保标注的准确性和一致性。
- 数据整合与存储：将标注后的数据整合，形成__结构化的__数据集，存储在安全的数据仓库中，供模型训练使用。

Made by QuadAI

在下划线上填写答案，请勿修改其他内容。

智能化数据标注在文化遗产数字化保护中的应用指导方案

1. 数据标注工具与方法

- 图像标注：
  - 使用__Labelbox、VGG Image Annotator（VIA）或 LabelImg__等标注工具，为文化遗产图像添加边界框、多边形、点、线段等标注。
- 对于复杂的文物细节，可以使用语义分割或实例分割技术，精细到每个物体的每一部分。
- 三维模型标注：
  - 采用 MeshLab 或 Blender 等软件，对 3D 模型进行顶点、面、体素级别的标注。
  - 实现对模型内部结构和外部特征的全面标注。
- 属性标签：
  - 文物的材料、风格、时代、作者、位置等元数据，使用 CSV、JSON 等格式记录，并关联至相应的图像或模型。
  - 可以使用数据库管理系统（如 MySQL、MongoDB）来存储和管理这些信息。

2. 智能化辅助标注

- 深度学习模型：训练__基于卷积神经网络__的模型，如 Mask R-CNN、U-Net 等，用于自动识别和标记文物的特定特征。
- 模型训练数据集：构建一个包含大量已标注文化遗产图像的数据集，用于模型训练和验证。
- 模型迭代与优化：定期更新模型，引入新发现的文物类型和特征，提升识别精度。

3. 跨学科团队协作

- 组建由考古学家、艺术史家、计算机视觉专家、AI 工程师组成的__跨学科__团队，共同制定标注标准和工作流程。
- 定期举行会议，讨论标注过程中的问题，调整标注策略。

4. 数据安全与隐私保护

- 使用__加密技术__存储和传输数据，确保文化遗产信息不被非法获取。
- 遵守相关法律法规，特别是涉及文化遗产的所有权和使用权的规定。

5. 用户体验与公众教育

- 开发 Web 应用或移动应用程序，允许用户在线浏览、搜索和学习文化遗产的数字化资料。
- 利用__AR/VR__技术，为用户提供沉浸式文化遗产体验，增加教育和娱乐价值。

6. 技术融合与未来展望

- 探索区块链技术的应用，为文化遗产的数字档案提供不可篡改的记录，增强其权威性和可信度。
- 结合 AI 和物联网技术，监测和预警文化遗产的物理状态变化，及时采取保护措施。

Made by QuadAIT